

分离多路卷积神经网络研究

宋 超, 许道云, 秦永彬

(贵州大学 计算机科学与技术学院, 贵阳 550025)

摘 要: 针对卷积神经网络主要使用图像的局部特征而忽略图像通道特征的不足, 提出一种分离多路卷积神经网络。提取通道特征与卷积特征, 并在全连接层进行融合, 以此提升该网络的图像识别与分类效果。在 cifar10 和 SVHN 数据集上进行的实验结果表明, 与 ResNet, Network in Network, Maxout 等 8 种卷积神经网络相比, 该网络的平均识别率较高。

关键词: 卷积神经网络; 深度学习; 特征提取; 图像分类; 图像识别; 通道特征

中文引用格式: 宋 超, 许道云, 秦永彬. 分离多路卷积神经网络研究[J]. 计算机工程, 2017, 43(6): 145-149, 157.

英文引用格式: Song Chao, Xu Daoyun, Qin Yongbin. Research on Detached Multiple Convolutional Neural Network[J]. Computer Engineering, 2017, 43(6): 145-149, 157.

Research on Detached Multiple Convolutional Neural Network

SONG Chao, XU Daoyun, QIN Yongbin

(College of Computer Science and Technology, Guizhou University, Guiyang 550025, China)

【Abstract】 As the Convolutional Neural Network (CNN) mainly uses the local features of the image, ignoring image channel features, this paper proposes a Detached Multiple Convolutional Neural Network (DMCNN). It extracts the channel features and convolution features, and fuses them in the whole connection layer so that image recognition and classification effects of the proposed network are improved. The experimental results on cifar10 and SVHN datasets show that the average recognition rate of the network is higher than that of other 8 CNNs like ResNet, Network in Network, Maxout.

【Key words】 Convolutional Neural Network (CNN); deep learning; feature extraction; image classification; image recognition; channel characteristic

DOI: 10.3969/j.issn.1000-3428.2017.06.024

0 概述

卷积神经网络于 1989 年首次被提出, 在手写字符识别方面取得了惊人的效果。2006 年提出的深度信念网络 (Deep Belief Network, DBN) 开启了深度学习时代, 其中主要得益于硬件的高速发展以及数据量爆炸式的增长, 使得大规模数据的计算成为可能^[1]。深度学习近年来发展迅速, 其中在图像识别与分类的应用方面, 卷积神经网络发挥了重要作用。自从卷积网络产生以来, 图像的特征提取就由原来传统的人工标识特征提取, 转换成通过卷积神经网络中的卷积层进行特征提取, 通常认为是符

合机器识别的特征。主流的卷积神经网络结构主要是用来提取图像的局部特征, 将获取的这些局部特征进行融合, 进而得到特征图像, 使用新特征图像再进行分类。目前, 对网络结构的一些改进主要集中在以下方面: 网络深度的加深, 如 ResNet^[2]; 使用网络嵌套代替原有的计算, 如 Network in Network^[3]; 对损失函数的改进, 如 PRELU^[4] 等。从数学角度与实际的使用角度都对网络的定义产生巨大的变化。这些新颖的网络结构弥补了对于原有网络的局限, 也为多元化组合奠定了基础。然而针对图像特征提取, 现有研究大多没有考虑到通道特征的延伸性。作为对这一特征的补充, 本文提

基金项目: 国家自然科学基金 (61262006, 61540050); 贵州省重大应用基础研究项目 (黔科合 JZ 字 [2014]2001); 贵州省科技厅联合基金 (黔科合 LH 字 [2014]7636 号)。

作者简介: 宋 超 (1989—), 男, 硕士研究生, 主研方向为图像识别; 许道云 (通信作者), 教授、博士生导师; 秦永彬, 副教授、博士。

收稿日期: 2016-08-04 修回日期: 2016-09-13 E-mail: dyxu@gzu.edu.cn

出一种基于分离通道的卷积神经网络,使用 cifar10 和 SVHN 数据集进行验证,并对最终的分类效果进行分析。

1 CNN 网络

卷积神经网络(Convolutional Neural Network, CNN)^[5]出现得比较早,其卷积特性在图像处理上具有独特的作用,卷积神经网络保存了图像的 sift 特征及平移不变性等,比原始依靠人工领域知识进行特征提取更加便捷有效。

目前所使用的卷积神经网络模型的基本结构主要是由卷积层、激活层、池化层、全连接层所组成。其中,卷积层进行图像局部特征提取;激活层进行数据非线性化;池化层进行空间的位置学习,并减少参数的数量;全连接层是对特征进行重组。主要结构如图 1 所示。




图 1 CNN 的基本框架

CNN 的操作依次是卷积、激活函数的激活、正规化、池化。多数文章将以上这 4 个部分统称为一个卷积的单元,将这 4 个部分作为一个单元,之后是多个这样的操作单元组合,输出多个特征图,最后对所有特征图进行全连接操作。全连接是将之前学习到的特征进行组合预测输出,一般将损失函数加在这一层,从而利用 BP 算法计算出整个网络的权重。随着深度学习的不断发展与演化,卷积神经网络也在进行不断的进化,同时每一层也是在不断变化的。卷积层的改变主要有 2 点: 1) 在 Network in Network 中提出使用一个多层感知机仿制一个卷积过程; 2) 在 GoogLeNet^[6]中提出,没有改变计算的本质,只是在同一个卷积层使用多种大小卷积核计算出多个特征图,之后对这些特征图进行合并。激活函数的变化由最初的 sigmoid, tanh 变成了 RELU, PRELU, LRELU, maxout^[7] 等非线性的函数。在激活函数之后,增加规则化的过程,使得其输出可以在 $[0, 1]$ 范围之内,从而达到加速收敛的效果,如 BatchNormal^[8], LRN。为了防止过拟合,增加了 dropout^[9] 和 dropconnect^[10] 的操作。

在训练阶段,随机地使网络中部分连接失效,目的在于削弱单元之间的依赖关系,而在测试和使用阶段保持所有连接可用,该操作集中在全连接层训练时使用。池化是减少网络参数的操作,并起到数据降维的作用,常用的池化操作是最大值池化和均值池化。全连接层增加了部分连接的方式,将隐含单元分组连接,这样可以起到部分参数共享,进而达到减少参数的目的。还有利用图像的放大缩小特征的多级金字塔卷积神经网络,可以加速特征的提取^[11],目前还有许多变形的深度学习网络。

2 分离多路卷积神经网络

在图像处理中,输入经常是彩色图像,而不是像手写字符的二值图像。对于彩色图像如 RGB 图像,基本的图像表示是 $N \times W \times H$, N 表示通道, W 表示图像的宽度, H 表示图像的高度,对于 RGB 图像, N 值就是 3,对于手写字符的二值图像, N 值就是 1。通道是一个原始特征图像,例如 RGB 的 3 个通道的特征是相互补充的,最终合并在一起,最后展现出所看到的一幅图像。类似于卷积的过程中图像的局部通道特征,对每一个通道而言,通道特征也可以作为一种独特的特征来使用。本文将全图的局部特征与通道特征一起考虑,进行图像特征提取和分类。

输入原始图像,首先对图像进行通道分割。这里使用 RGB 三色通道,故在此分成 3 个通道,也可以使用其他颜色空间进行分配。分别将每个通道进行隔离、卷积、池化。其中,卷积操作是一种部分加权求和的过程,最终得到一个单通道输出的特征图,进而对所产生的特征图像进行连接。在分离通道提取特征的最后,使用 2 种方式组合进行特征融合: 1) 在通道内部,使用类似 maxout 的方法将所有的特征图按照像素点进行比较,保留最大的点,进而得到一张新的特征图。但是这样丢失的特征比较大,因此对特征图像又使用了一个均值化的采样,叠加出一个特征图,作为补充特征图。以这种方式,每一个分离通道最后都会产生 2 张大小相同的特征图,在此称作局部特征连接。2) 全局特征融合,在上述局部特征的基础上将局部特征图以加权融合的方式进行组合。

具体计算如下: 局部特征连接使用的方法是在得到 d 张特征图后,将对应的点都看作是一个相同

的水平管道, 对在一个管道中的点都按照下式计算最大值:

$$h_i(x) = \max_{j \in [1, k]} z_{ij} \quad (1)$$

$$h_i(x) = \frac{1}{k} \sum_{j \in [1, k]} z_{ij} \quad (2)$$

其中, $z_{ij} = x^T W_{ij} + b_{ij}$; $W \in \mathbb{R}^{d \times m \times k}$, $b \in \mathbb{R}^{m \times k}$; $x \in \mathbb{R}^d$. z_{ij} 表示的是未融合的特征图; W 表示卷积核的值; b 表示偏置项; x 表示卷积之前的输入; h_i 为所求的目标。通过式(1)、式(2)将通道中的特征融合在一起, 最大值融合与均值融合没有进行权值的计算, 避免计算时额外引入网络参数的影响。

全局连接的计算, 是在整张特征图的全卷积计算之后进行, 使用全连的方式, 得到特征的组合, 公式如下:

$$z_{ij} = x^T W_{ij} + b_{ij} \quad (3)$$

其中, $W \in \mathbb{R}^{d \times m \times k}$; $b \in \mathbb{R}^{m \times k}$; $x \in \mathbb{R}^d$. z_{ij} 表示特征融合之后的值; W 表示组合的权重值; b 表示偏置项; x 表示局部特征的数据值。之所以分成局部融合和全局融合是为了分别对特征进行凸显(主要是最大值的提取, 但是会丢失很多信息, 在此用均值作为补充)和叠加各个通道最终凸显的特征区域, 后面的全连接中可以减少连接参数, 进而起到一定的防止过拟合效果。在单通道的过程中仍使用 PRELU 激活函数, 对 PRELU 补充了输入参数小于 0 的处理。

$$f(y_i) = \begin{cases} y_i, & y_i > 0 \\ \alpha_i y_i, & y_i < 0 \end{cases} \quad (4)$$

其中, $y_i \in \mathbb{R}^d$; $\alpha_i \in [0, 0.5]$; y_i 表示像素的输入; α_i 表示当 y_i 小于 0 时 y_i 的权重。

最后使用 2 层的全连接进行特征融合, 使用全连接对特征点进行权值化, 在此使用的是 2 次全连接, 前一次看作是权重化的先验过程, 后一次是偏置化, 主要用来分类, 在此使用 softmax 进行目标分类的损失计算。

$$h_\theta(x^{(i)}) = \begin{bmatrix} p(y^{(i)} = 1 | x^{(i)}; \theta) \\ p(y^{(i)} = 2 | x^{(i)}; \theta) \\ \vdots \\ p(y^{(i)} = k | x^{(i)}; \theta) \end{bmatrix} = \frac{1}{\sum_{j=1}^k e^{\theta_j^T x^{(i)}}} \begin{bmatrix} e^{\theta_1^T x^{(i)}} \\ e^{\theta_2^T x^{(i)}} \\ \vdots \\ e^{\theta_k^T x^{(i)}} \end{bmatrix} \quad (5)$$

其中, $\theta_1, \theta_2, \dots, \theta_k \in \mathbb{R}^{n+1}$ 是 softmax 的模型参数; $\sum_{j=1}^k e^{\theta_j^T x^{(i)}}$ 用来进行归一化; $h_\theta(x^{(i)})$ 表示分类的输出。

为了加速整个网络的学习及突出通道特征, 在此使用了 googlenet 中提到的多个损失函数, 对模型中每一个通道添加了一个 softmax 分类的校准函数, 用来加强特征学习与参数学习, 在 BP(反向传播)阶段增强特征提取, 也可使其快速收敛。最后在单通道的计算中考虑到过拟合问题, 使用 dropout 层, 进而在训练时随机丢弃部分连接, 减少参数, 达到一种更好的泛化作用。

分离的多路卷积神经网络(Detached Multiple Convolution Neural Network, DMCNN)采用了一种端到端的训练过程, 以增强各个部分训练的连续性。

3 实验结果与分析

本文进行识别实验所使用的公共数据集是 cifar10^[12]、SVHN。其中, cifar10 是 10 分类的数据集, 包含 10 种不同的目标, 其训练集有 50 000 张图像, 测试集有 10 000 张图像; SVHN 数据集是街景的房子门牌数据集, 类似于 mnist 手写字符数据集, 但是这个数据集是彩色图像。基本环境为 Ubuntu14.04, 采用 caffe^[13] 框架, 并使用 GPU 进行加速处理。

在实验设置方面, 实验使用的是 caffe 的 model 中已经带有的数据集(cifar10)、SVHN 从官网下载, 经过定制化的脚本进行矩阵化处理, 并最终转化为 caffe 所使用的 lmdb 格式, 在此不做任何的数据扩展, 而是使用原始的数据集进行比对。图 2 是网络的整体结构图。channel 表示将图像划分的通道, 这里使用的是 RGB 三色通道空间, 划分成 3 个主要通道, conv 表示卷积、激活函数、batch-Norm、池化 4 个组成单元。conn 表示通道内的全连接; full-connect 表示全局的全连接; class 表示分类; loss 表示损失函数。dropout 没有在图中画出。损失函数和 dropout 都是在训练时使用, 实际的测试阶段不进行计算。具体的网络配置为: 输入 32 像素 × 32 像素 RGB 的图像, RGB 通道各有 1 个 3 × 3 卷积, 16 PRelu, batch-norm, 2 × 2 池化(max) 和 3 个 3 × 3 卷积, 32 PRelu, batch-norm, 2 × 2 池化(ave), maxout, Dropout 0.5 (TEST), 全连接, softmax (TEST) 以及 1 个 4 × 4 卷积, 带权全连接, 全连接(神经网络), 10 分类的 softmax 函数。其中标识为 TEST 的方法在测试阶段不进行计算, 这些操作只是在训练时使用, 其他的操作在训练与测试时都使用。cifar10 数据集上的实验结果如表 1 所示。

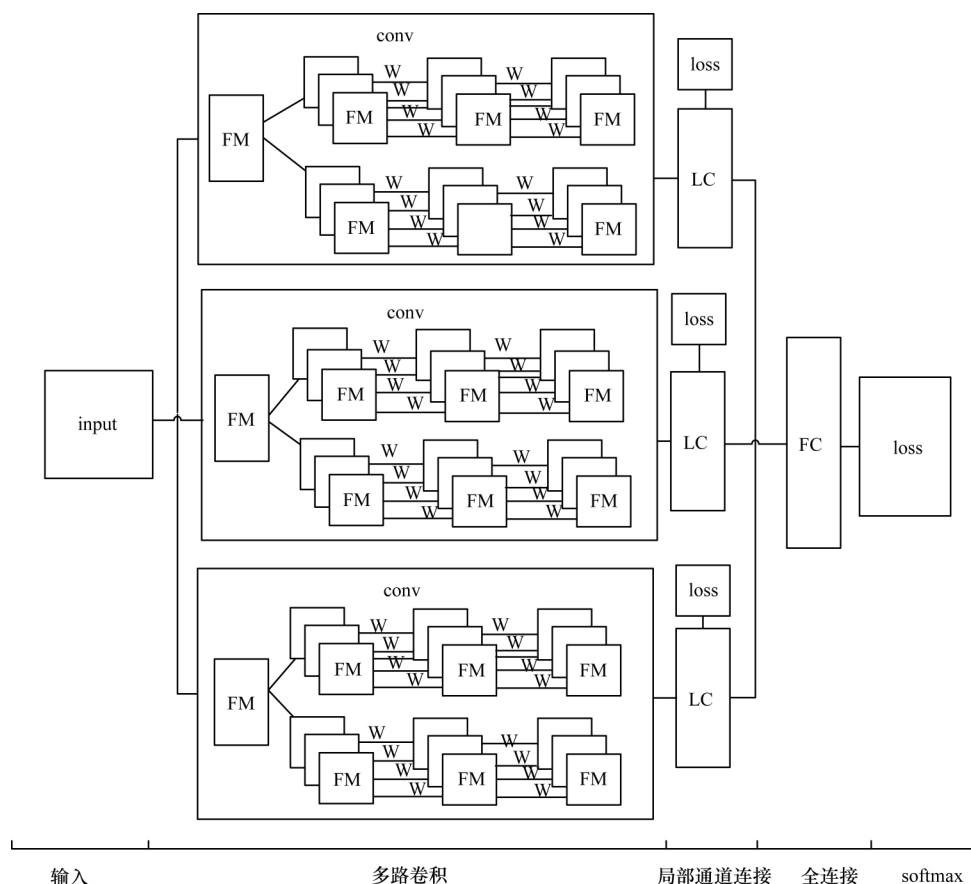


图 2 分离多路卷积神经网络结构

表 1 未经数据扩展的 cifar10 数据集实验结果 %

网络	错误率
ResNet ^[2]	18.47
Network in Network ^[3]	22.16
Maxout ^[7]	27.73
All-convolution ^[14]	14.23
Batch-Norm Maxout ^[15]	21.71
Deeply Supervised ^[11]	19.61
googlenet	23.85
alexnet	21.35
DMCNN	13.25

表 2 未经数据扩展的 SVHN 数据集实验结果 %

网络	错误率
ResNet ^[2]	7.43
Network in Network ^[3]	10.03
Maxout ^[7]	9.27
All-convolution ^[14]	12.23
Batch-Norm Maxout ^[15]	10.26
Deeply Supervised ^[11]	11.31
googlenet	11.85
alexnet	17.26
DMCNN	8.23

对比上述网络结构的计算结果,本文实验并未对原始数据集进行处理,只是在 caffe 中做了一个数据格式的压缩,使用 lmdb 格式。在对网络的训练过程中,使用随机梯度下降方法并保持动量参数为 0.9,初始学习率为 0.01,权重衰减策略参数使用的是默认的参数。SVHN 数据集上的实验结果如表 2 所示。

在不同数据集上进行训练时,需要依据数据集的差异调整网络优化策略,在 cifar10 和 SVHN 数据集上使用了不同的优化参数,主要的不同是学习率在 0.001 ~ 0.1 范围内的设置。

通过对比表 1、表 2 可以看出,使用多通道的分离可以得到一些通道特征,这些隐含的通道特征使得分类的准确率得到了明显提升。通道的隐含特征对于最终的组合特征起到了增强分类的作用。对比之前

的网络结构, 本文的结构增加了通道的隔离计算策略和网络的可选路径机制, 使得网络的通路变大。最近流行的残差网络, 其提出的加深深度网络的设计本质上是一种增加网络的分支路径方法, 在网络加深的同时, 扩大了网络的组合情景, 以此获得较好的识别准确率。因此, 将分离多路卷积神经网络看作是对通道的一种重组策略, 增强网络的组合效应。

分别从 cifar10 和 SVHN 中提取网络中第 2 层中的 36 张特征图像作比较, 如图 3 所示, 前 4 幅描述的是在识别“狗”这张图像时, 通过不同的管道提取的特征图像, 其中, a1 表示的是在 R 大通道上的特征; a2 表示的是在 G 大通道上的特征; a3 表示的是在 B 大通道上的特征。从 a1, a2, a3 这 3 幅特征图中可以看到, 对轮廓及内部细节不同程度上的提取, 每个通道对特征空间表达具有差异性, 网络根据差异进行不同分布的特征提取。后 4 幅图表示的是对图像中的数字“1”进行识别, 要最大限度地关注“1”, 而忽略其他的干扰, 经过训练的网络提取这一独特性质时, 也是根据不同通道的差异进行最大限度的特征提取。在 b1, b2, b3 这 3 幅特征图中可以观察到对于“1”的特征加强与区分, 进而将周围的干扰降低, 以突出所需要的特征。通过对比, 从图中可以看出, 在不同的通道中, 处理特征存在巨大的差异, 而且在通道内部每个分支提取的特征也是可以互补的。由于每一个卷积核所得到的局部特征的侧重点是不同的, 利用差异性, 可以用来关注不同的特征点, 从而在最后的组合中提升特征的表达能力。

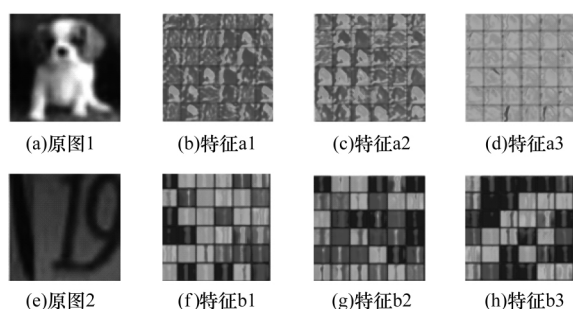


图3 第2层3个大通道的特征提取

图 4 展示的是训练过程中的损失函数与迭代的训练的曲线图, c1 表示的是在 cifar10 上面的损失曲线图, c2 表示的是在 SVHN 上的损失曲线图。从 c1, c2 中可以观察到, 在训练到 40 000 次左右时, 曲线基本趋于一种较低损失的水平, 在学习的过程中, 开始的 10 000 次迭代基本上处于一个快速收敛的过程。通过观察 loss 的曲线图^[16]也可以判定此时训练的过程是否符合一般判定原则, 以此快速判定网络的训练策略是否正确。




图4 训练时损失值的曲线

4 结束语

本文通过在卷积神经网络中加入分离的通道特征融合策略, 使得特征强度得到提升, 证实通道的隐含特征对于分类的效果具有一定的影响。该策略在分类的准确率上有待提升, 可以在现有的数据集上使用当前比较流行的数据扩展方法进行数据扩充, 增大数据集以提升分类的准确度; 同时, 将一些传统特征融合到深度网络进行二次特征提取, 以增加样本的多样性, 提升网络的特征数, 通过增加分类的特征集提升分类准确度。然而, 本文策略在进行调参时耗时较多, 且对先验知识有一定的要求。下一步将针对这些局限加以改进, 采用更好的方法解决调参繁琐的问题。

参考文献

- [1] 余凯, 贾磊, 陈雨强, 等. 深度学习的昨天, 今天和明天[J]. 计算机研究与发展, 2013, 50(9): 1799-1804.
- [2] He Kaiming, Zhang Xiangyu, Ren Shaoqing, et al. Deep Residual Learning for Image Recognition [C]// Proceedings of IEEE Conference on Computer Vision and Pattern Recognition. Washington D. C., USA: IEEE Press, 2015: 770-778.
- [3] Lin Min, Chen Qiang, Yan Shuicheng. Network in Network [EB/OL]. (2014-03-04). <https://arxiv.org/abs/1312.4400>.
- [4] He Kaiming, Zhang Xiangyu, Ren Shaoqing, et al. Delving Deep into Rectifiers: Surpassing Human-level Performance on Image Net Classification [C]// Proceedings of the IEEE International Conference on Computer Vision. Washington D. C., USA: IEEE Press, 2015: 1026-1034.
- [5] LeCun Y, Bengio Y. Convolutional Networks for Images, Speech and Time Series [M]// Arbib M A. The Handbook of Brain Theory and Neural Networks. New York, USA: ACM Press, 1995.

(下转第157页)

5 结束语

本文基于标注 LDA 分析后的吉布斯采样结果计算给定主题下 2 个单词共现的条件概率,相较于 PL-LDA 方法来说,运算量更小,所需时间更少。在航空安全报告数据集上的实验结果表明,对标记单词较多的主题 2 种方法所得结果差别不大,用其构建的主题文本网络可以直观的方式展示主题词的分布情况以及它们之间的复杂联系,主题词对补充和丰富了主题词的解释并提供了额外的有效信息,对领域工程师的分析具有辅助作用。而对于标记单词较少的小规模主题,本文方法所得结果解释性较差,需要作进一步的研究和改进。

参考文献

- [1] Blei D M, Ng A Y, Jordan M I. Latent Dirichlet Allocation[J]. Journal of Machine Learning Research, 2003 3: 993-1022.
- [2] Zhang Duo, Zhai Chengxiang, Han Jiawei, et al. Topic Modeling for OLAP on Multidimensional Text Databases: Topic Cube and Its Applications [J]. Statistical Analysis and Data Mining: The ASA Data Science Journal 2009 2(5/6): 378-395.
- [3] Blei D M, McCalliffe J D. Supervised Topic Models [J]. Advances in Neural Information Processing Systems, 2010 3: 327-332.
- [4] Ramage D, Hall D, Nallapati R, et al. Labeled LDA: A Supervised Topic Model for Credit Attribution in Multi-labeled Corpora [C]//Proceedings of 2009 Conference on Empirical Methods in Natural Language Processing. New York, USA: ACM Press 2009: 248-256.
- [5] 张青, 吕钊. 基于主题扩展的领域问题分类方法[J]. 计算机工程 2016 42(9): 202-207 213.
- [6] 常鹏, 冯楠, 马辉. 一种基于词共现的文档聚类算法[J]. 计算机工程 2012 38(2): 213-214.
- [7] 耿焕同, 蔡庆生, 于琨, 等. 一种基于词共现图的文档主题词自动抽取方法[J]. 南京大学学报(自然科学版) 2006 42(2): 156-162.
- [8] 赵文清, 侯小可. 基于词共现图的中文微博新闻话题识别[J]. 智能系统学报 2012 7(5): 444-449.
- [9] Church K W, Hanks P. Word Association Norms, Mutual Information, and Lexicography [J]. Computational Linguistics 1990 16(1): 22-29.
- [10] Manning C, Schütze H. Foundations of Statistical Natural Language Processing [M]. Cambridge, USA: MIT Press, 1999.
- [11] Turney P. Mining the Web for Synonyms: PMI-IR Versus LSA on TOEFL [C]//Proceedings of the 12th European Conference on Machine Learning. New York, USA: ACM Press 2001: 491-502.
- [12] 王振宇, 吴泽衡, 胡方涛. 基于 HowNet 和 PMI 的词语情感极性计算[J]. 计算机工程 2012 38(15): 187-189.
- [13] 周剑峰, 阳爱民, 周咏梅, 等. 基于二元搭配词的微博情感特征选择[J]. 计算机工程 2014 40(6): 162-165.
- [14] Smith A, Chuang J, Hu Y, et al. Concurrent Visualization of Relationships Between Words and Topics in Topic Models [C]//Proceedings of Workshop on Interactive Language Learning, Visualization, and Interfaces. Baltimore, USA: [s. n.] 2014: 79-82.
- [15] Han Lushan, Finin T, McNamee P, et al. Improving Word Similarity by Augmenting PMI with Estimates of Word Polysemy [J]. IEEE Transactions on Knowledge and Data Engineering 2013 25(6): 1307-1322.
- [16] 张志远, 霍伟纲. 一种基于 PL-LDA 模型的主题文本网络构建方法 [EB/OL]. [2016-08-22]. <http://pan.baidu.com/s/1o8gxru1>.
- 编辑 顾逸斐
-
- (上接第 149 页)
- [6] Szegedy C, Liu Wei, Jia Yangqing, et al. Going Deeper with Convolutions [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Washington D. C., USA: IEEE Press 2015: 1-9.
- [7] Goodfellow I J, Warde-Farley D, Mirza M, et al. Maxout Networks [EB/OL]. (2013-02-18). <https://arxiv.org/abs/1302.4389>.
- [8] Lee C Y, Xie Saining, Gallagher P, et al. Deeply-supervised Nets [EB/OL]. (2014-03-22). <http://vcl.ucsd.edu/~sxie/2014/09/12/dsn-project>.
- [9] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting [J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [10] Li Wan, Zeiler M, Zhang Sixin, et al. Regularization of Neural Networks Using Ropconnect [C]//Proceedings of the 30th International Conference on Machine Learning. New York, USA: ACM Press 2013: 1058-1066.
- [11] 王冠皓, 徐军. 基于多级金字塔卷积神经网络的快速特征表示方法[J]. 计算机应用研究 2015 32(8): 2492-2495.
- [12] Krizhevsky A, Nair V, Hinton G. The CIFAR-10 Dataset [EB/OL]. (2013-11-14). <http://www.cs.toronto.edu/~kriz/cifar.html>.
- [13] Jia Yangqing, Shelhamer E, Donahue J, et al. Caffe: Convolutional Architecture for Fast Feature Embedding [C]//Proceedings of ACM International Conference on Multimedia. New York, USA: ACM Press 2014: 675-678.
- [14] Springenberg J T, Dosovitskiy A, Brox T, et al. Striving for Simplicity: The All Convolutional Net [EB/OL]. (2014-12-21). <https://arxiv.org/abs/1412.6806>.
- [15] Chang Jiaren, Chen Yongsheng. Batch-normalized Maxout Network in Network [EB/OL]. (2015-11-09). <https://arxiv.org/abs/1511.02583>.
- [16] 李航. 统计学习方法 [M]. 北京: 清华大学出版社 2012.
- 编辑 顾逸斐