

## 基于改进 VGG 卷积神经网络的棉花病害识别模型

张建华<sup>1</sup> 孔繁涛<sup>1</sup> 吴建寨<sup>1\*</sup> 翟治芬<sup>2</sup> 韩书庆<sup>1</sup> 曹姗姗<sup>1</sup>

(1. 中国农业科学院 农业信息研究所/农业部农业信息服务技术重点实验室, 北京 100081;

2. 农业部规划设计研究院, 北京 100125)

**摘要** 为实现自然条件下棉花病害图像准确分类, 提出基于改进 VGG-16 卷积神经网络的病害识别模型。该模型在 VGG-16 网络模型基础上, 优化全连接层层数, 并用 6 标签 SoftMax 分类器替换原有 VGG-16 网络中的 SoftMax 分类器, 优化了模型结构和参数, 通过微型迁移学习共享预训练模型中卷积层与池化层的权值参数。从构建的棉花病害图像库中随机抽取病害图像样本作为训练集和测试集, 用以测试该方法的性能。试验结果表明: 该模型能有效提取出棉花病害叶片图像的多层特征图像, 并通过 Relu 激活函数的处理更能凸显棉花病害的边缘信息与纹理信息, 分辨率为 512 像素×512 像素图像在样本训练与验证试验效果最好。在平均识别准确率方面, 本研究模型较 BP 神经网络、支持向量机、AlexNET、GoogleNET、VGG-16NET 效果最好, 达到 89.51%, 实现对棉花的褐斑病、炭疽病、黄萎病、枯萎病、轮纹病、正常叶片的准确区分。该模型在棉花病害识别领域具备良好的分类性能, 可实现自然条件下棉花病害的准确识别。

**关键词** 棉花; 卷积神经网络; VGG 网络; 病害; 图像识别

中图分类号 S431

文章编号 1007-4333(2018)11-0161-11

文献标志码 A

## Cotton disease identification model based on improved VGG convolution neural network

ZHANG Jianhua<sup>1</sup>, KONG Fantao<sup>1</sup>, WU Jianzhai<sup>1\*</sup>, ZHAI zhifen<sup>2</sup>, HAN Shuqing<sup>1</sup>, CAO Shanshan<sup>1</sup>

(1. Agricultural Information Institute/Key Laboratory of Agri-information Services Technology of Ministry of Agriculture,

Chinese Academy of Agricultural Sciences, Beijing 100081, China;

2. Chinese Academy of Agricultural Engineering, Beijing 100125, China)

**Abstract** In order to classify the cotton disease images accurately under natural conditions, a disease identification method based on the improved VGG-16 convolution neural network is proposed. Based on the VGG-16 network model, this method replaces the original three fully connected layers with two fully connected layers, and replaces the SoftMax classifier in the original VGG-16 network with the 6-tag SoftMax classifier. These changes can optimize the model structure and parameters, and it can share the weight parameters of the convolutional layer and the pooling layer in the pre-training model through the mini-migration learning. From the constructed image database of cotton diseases, the images of disease images were randomly taken as training set and test set to test the performance of the method. The experimental results show that this method can effectively extract multi-layer feature images of cotton leaf disease images, and it can highlight the edge information and texture information from cotton disease feature map through the Relu activation function. In the four kinds of resolution image samples training and verification, 512 pixels × 512 pixels resolution images are the best fit for testing. Compared with BP neural network, support vector machine, AlexNET, GoogleNET and VGG-16NET, the proposed method has the best performance in average recognition accuracy of 89.51%. It is better to distinguish *Cercospora* leaf spot, *Anthraxnose*, *Verticillium* wilt, *Fusarium* wilt, wheel

收稿日期: 2018-03-08

基金项目: 国家自然科学基金项目(31501229); 中央级公益性科研院所基本科研业务费专项(Y2018PT35, Y2018PT82, JBYW-AII-2017-05)

第一作者: 张建华, 副研究员, 主要从事图像处理与图像识别研究, E-mail: zhangjianhua@caas.cn

通讯作者: 吴建寨, 副研究员, 主要从事地理信息系统研究, E-mail: wujianzhai@caas.cn

disease and health leaf. The results show that the method has good classification performance in the field of cotton disease identification, and can realize accurate identification of cotton diseases under natural conditions.

Keywords cotton; convolution neural network; VGG network; diseases; image recognition

棉花是我国重要的经济作物和纺织原料,是重要的战略物资<sup>[1]</sup>。棉花在生育周期中容易受到多种病害的侵入,进而影响其最终产量和品质,严重时会造成棉花绝收<sup>[2-3]</sup>。一方面,棉花病害诊断是通过肉眼观察或网上专家诊断方式(如 plant village 网站),这些方法容易出现心理和认知的差异,导致人为误诊;另一方面,通过病害分析诊断方式,在病原物培养基础上,结合显微镜观察方法,可以较好的检测病害类别,但该方式比较耗时,无法及时提供诊断结果<sup>[4-6]</sup>。

随着机器视觉和人工智能技术的发展,基于可见光和近红外光谱数字图像的作物病害诊断水平获得了快速提高。由于近红外光谱和高光谱图像比可见光图像中承载更多信息,获得了大量研究学者的青睐,也产生了较多的成果,但存在的缺陷是获取图像的设备通常比较笨重和昂贵,从而限制了该项技术的大面积应用<sup>[7-8]</sup>。而可见光图像可通过数码相机、智能手机、摄像机等多种普通电子设备获取,使得可见光范围的病害图像识别研究更有意义<sup>[9-10]</sup>。

在可见光作物病害图像识别研究中,大多采用传统的分类识别方法。Camargo 等<sup>[11]</sup>开展了棉花病害的特征提取和支持向量机分类器研究,识别了3种棉花病害。Phadikar 等<sup>[12]</sup>利用粗糙集理论构建了最小化损失的水稻病害分类器,获得了一定效果。Zhang 等<sup>[13]</sup>采用稀疏表示方法成功诊断了黄爪叶片病害,但仍需进一步完善字典结构。Barbedo 等<sup>[14]</sup>基于颜色矩分类识别了多种植物病害。Chung 等<sup>[15]</sup>构建了基于 SVM 的水稻幼苗病害识别模型,能够检测恶苗病,检测准确率有待进一步提高。张建华等<sup>[16]</sup>利用粗糙集和 BP 神经网络构建了棉花病害识别模型。Zhou 等<sup>[17]</sup>在定向代码匹配方法基础上,检测了甜菜病害。黄双萍等<sup>[18]</sup>提出了基于深度卷积神经网络 GoogLeNet 模型的水稻穗瘟病检测方法,较浅层神经网络性能有较大提高。Cheng 等<sup>[19]</sup>构建了一种利用深度学习的害虫识别模型,改善了复杂农田背景下的害虫识别率,但在深度残差学习方法中需进一步融合。Lu 等<sup>[20]</sup>根据 VGG 卷积神经网络理论方法,构建了一种大田环境

下小麦疾病自动诊断系统,实现了15种小麦病害的识别。综上,传统的病害分类识别方法中,都需要人为的选择病害的特征并进行提取,缺乏病害特征的自学习,当针对某种病害时采用这种方式效果较好,但在不同背景、不同天气和不同危害程度等多种条件下获取病害图像时,往往其适用性受到抑制,识别效果一般。而深度学习方法特别是卷积神经网络模型(Convolutional neural networks, CNN)在大田自然复杂环境中比较好的优势。

在棉花生长发育过程中,褐斑病、炭疽病、黄萎病、枯萎病、轮纹病以及正常叶片彼此间的病害症状极为相似,容易混淆而使人分辨不清,造成病害分类识别结果错误;而卷积神经网络是一种深度学习模型,通过多层次卷积计算,能自动学习和抽象表达,是性能优秀的分类器。因此,本研究引入卷积神经网络分类器,结合深度学习理论,旨在构建5种棉花叶部病害与正常叶片的分类识别模型,以期对棉花病害特征的自学习和训练,形成棉花病害分类器,对自然光条件下的棉花病害进行识别。

## 1 试验材料与方法

### 1.1 棉花病害图像获取

2015—2017年在中国农业大学北京市海淀区农业试验基地,采集棉花自然环境下采集棉花病害叶片图像。棉花品种为 BT 转基因棉,棉花种植分为白地膜、黑地膜、秸秆和裸土4种土壤覆盖方式,采集的棉花生长阶段集中在苗期、拔节期、花期阶段,为了充分考虑自然场景的天气条件,分别选择了晴天、阴天进行图像采集。为了获取的图像有较大的代表性,采集方式为距离棉花叶片30~50 cm,选择相机与棉花叶片垂直角度和50°~80°倾角等2种方式拍摄。采集设备为佳能单反数码相机,型号为 EOS 50D,焦距设定为:自动智能对焦,采集图像的分辨率为1 024 像素×768 像素。共采集5 510幅棉花病害图像,形成了棉花病害图像库,分别为褐斑病915幅、炭疽病840幅、黄萎病970幅、枯萎病910幅、轮纹病875幅、正常叶片1 000幅,用于棉花病害的训练与测试,棉花病害种类的识别通过棉花病理学专家判断与确认。棉花病害图像见图1。

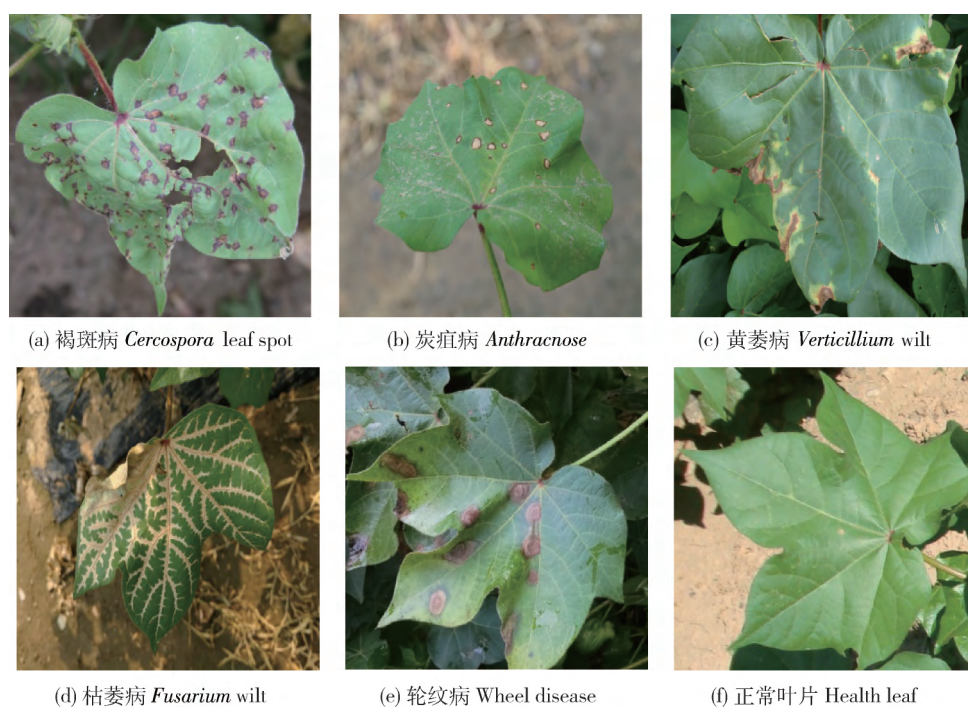


图 1 棉花病害图像

Fig. 1 Cotton disease images

## 1.2 试验方法

### 1.2.1 卷积神经网络

卷积神经网络是一种模拟人脑结构的多层次非全连接的神经网络,通过有监督的深度学习的神经网络,能够直接从原始图像中识别视觉模式<sup>[21-22]</sup>。CNN 模型一般由卷积层、池化层、全连接层、SoftMax 分类层等 4 个层次堆叠组成<sup>[23]</sup>。每层神经网络是构建在由独立分布的神经元组合而成的多个平面上,层与层之间的连接方式为非全连接的卷积计算,每个神经元是输入单元的部分维度值的加权。当前比较成功的 CNN 模型包括 Alex 网络、GoogLe 网络和 VGG-16 网络,能够对广义物体进行精确识别。

#### 1) 卷积层。

卷积层是通过若干个卷积核重复作用于不同位置的输入接受区域即图像块的每个感受野,并将卷积结果组合成特征图像<sup>[24]</sup>。卷积运算其实就是卷积层与输入接受区域进行的线性相关计算,具体公式为:

$$y_{\text{conv}} = f\left(\sum_{j=0}^{J-1} \sum_{i=0}^{I-1} x_{m+i, n+j} w_{ij} + b\right) \quad (0 \leq m \leq M, 0 \leq n \leq N) \quad (1)$$

式中:  $x$  为接受区域为  $(M, N)$  的二维向量;  $w$  为长和宽分别为  $j, i$  的卷积核;  $b$  为每个输出特征映射所

加的偏置项;  $y_{\text{conv}}$  为输出的卷积结果;  $M$  为二维向量的长,  $N$  为二维向量的宽;  $f$  即为激活函数。

#### 2) 池化层。

池化层主要作用为卷积计算结果进行尺度缩小的层,也可称为非线性下采样操作层,经过池化层处理后的特征图的尺度会一定程度减小<sup>[25]</sup>。常用的池化计算方法包括有平均池化、最大池化(Max Pooling)、重叠池化、高斯池化和随机池化,其中最经典池化方法为最大池化,以尺度为 2,步长为 2 的最大池化函数为:

$$f_{\text{pool}} = \text{Max}(x_{m,n}, x_{m+1,n}, x_{m,n+1}, x_{m+1,n+1}) \quad (0 \leq m \leq M, 0 \leq n \leq N) \quad (2)$$

式中,  $f_{\text{pool}}$  表示特征图像最大池化结果。

#### 3) 全连接层。

全连接层一般会在连续堆叠的卷积层、池化层与输出层之间,全连接层形成了一个类似浅层神经网络的多层感知机,全连接层则起到将学到的“分布式特征表示”映射到样本标记空间的作用<sup>[26]</sup>。研究表明,全连接层另一个作用为在模型表示能力迁移过程中充当“防火墙”的作用。

#### 4) SoftMax 分类层。

SoftMax 分类层是解决多分类问题的分类器,

是由 Logistic 回归模型应用到多分类问题上的演化结果<sup>[27]</sup>。由于 Logistic 函数只能进行二分任务, SoftMax 分类器是继承了 Logistic 函数的回归, 并利用多项 Logistic 回归实现多分类问题。在 Softmax 回归中的多分类标签  $y$  的取值的范围为  $y \geq 2$ , 训练样本集合是  $k$  个被标签的样本构成:

$$T = \{(x_{(1)}, y_{(1)}), (x_{(2)}, y_{(2)}), \dots, (x_{(k)}, y_{(k)})\} \quad (3)$$

式中:  $y_{(i)} \in \{1, 2, \dots, k\}$  为分类标签,  $x_{(i)}$  为样本集合。以  $j$  为不同的类别, 对  $j$  估算概率值, 单个样本判别为第  $k$  类标签的概率为:

$$P(y = j | x) \quad (j = 1, 2, \dots, k) \quad (4)$$

描述该回归样本集合转换为  $k$  维度的概率向量, 其函数为:

$$h(x_{(i)} | \theta) = \begin{bmatrix} p(y_{(i)} = 1 | x_{(i)}, \theta) \\ p(y_{(i)} = 2 | x_{(i)}, \theta) \\ \vdots \\ p(y_{(i)} = k | x_{(i)}, \theta) \end{bmatrix} = \frac{1}{\sum_{j=1}^k e^{\theta_j^T x_{(i)}}} \begin{bmatrix} e^{\theta_1^T x_{(i)}} \\ e^{\theta_2^T x_{(i)}} \\ \vdots \\ e^{\theta_k^T x_{(i)}} \end{bmatrix} \quad (5)$$

式中:  $\theta = [\theta_1^T, \theta_2^T, \dots, \theta_k^T]$  为模型的学习参数, 且  $\theta_1^T, \theta_2^T, \dots, \theta_k^T \in \mathbf{R}^{n+1}$ ;  $\frac{1}{\sum_{j=1}^k e^{\theta_j^T x_{(i)}}}$  的作用是将概率归一化处理并使得概率总和为 1。通过样本集的训练和学习, Softmax 分类器通过迭代优化方法拟合数据曲线, 同时调整参数  $\theta$  以最小化模型中的损失函

数值, 其损失函数公式为:

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^m \sum_{j=1}^k 1\{y_{(i)} = j\} \log \frac{e^{\theta_j^T x_{(i)}}}{\sum_{i=1}^k e^{\theta_i^T x_{(i)}}} \right] \quad (6)$$

式中:  $1\{y_{(i)} = j\}$  表示如果  $y_{(i)} = j$ , 则为 1, 否则为 0。随着损失函数的迭代, Softmax 分类器的参数进一步优化和明确, 使得对不同训练样本有了判别区分功能。

### 1.2.2 VGG-16 网络

VGG-16 网络是卷积神经网络中分类性能优秀的网络模型<sup>[28-29]</sup>。VGG-16 网络最大的特点是通过  $3 \times 3$  滤波器的组合与堆叠, 提取出输入领域内更多非常细小的特征<sup>[30]</sup>。通过构建和组合多个  $3 \times 3$  卷积核, 可以获得模板大小为  $5 \times 5$  或  $7 \times 7$  卷积核相同的计算效果, 连续小模板的卷积核比单个大的卷积核具有较好的非线性。

从图 2 可知, VGG-16 卷积神经网络包含了 16 个权重层, 分别为 13 个卷积层和 3 个全连接层组成。输入 1 幅  $224 \text{ 像素} \times 224 \text{ 像素} \times 3$  向量的图像, 在卷积层采用  $3 \times 3$  滤波器, 每 2 个或者 3 个滤波器连续堆叠组成卷积序列, 模仿出更大的感受野的效果, 滑动步长为 1, 并利用边界填充保持前后数据维数不变; 在池化层采用  $2 \times 2$  池化窗口, 步长为 2, 用于减小卷积后的特征图像尺寸大小, 以及确保模型的平移不变性; 在全连接层由 3 个连续的全连接进行组合, 通道数分别为 4 096、4 096、1 000 个; 最后由具有 1 000 个标签的 SoftMax 分类器进行分类输出。

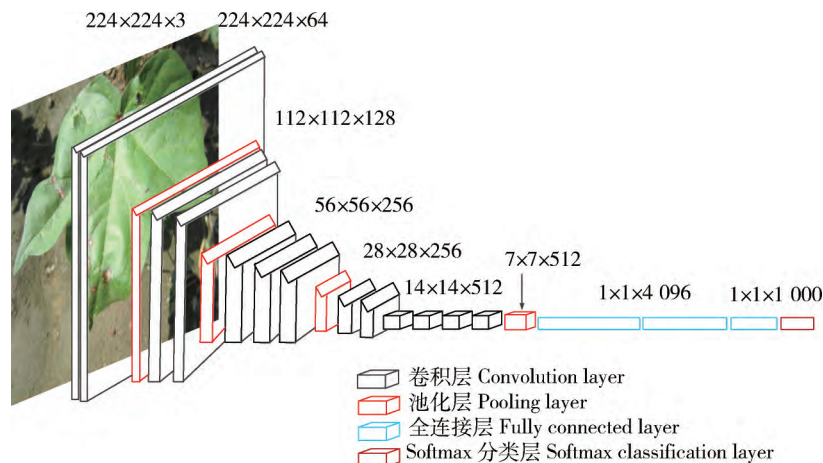


图 2 VGG-16 卷积神经网络的示意图

Fig. 2 VGG-16 convolutional neural network diagram



在 VGG-16 卷积神经网络的隐含层中都有激活函数的存在,激活函数使得神经网络有了非线性映射能力,通常激活函数包括 Sigmoid 函数、Tanh 函数和 ReLU 函数。而 ReLU 函数是不饱和函数,运算结果比较稀疏,能更多减小反向传播误差,加快网络的收敛速度。从学习速度和训练质量角度出发,选择 ReLU 函数将会更有效率。公式如下:

$$f_{\text{ReLU}}(x) = \begin{cases} 1 & (x \geq 0) \\ 0 & (x < 0) \end{cases}$$

式中: $f_{\text{ReLU}}$  为 ReLU 函数计算结果; $x$  表示接受区域的向量。ReLU 函数曲线见图 3。




图 3 ReLU 激活函数

Fig. 3 ReLU activation function

### 1.2.3 基于改进 VGG-16 网络的棉花病害识别模型

基于 VGG-16 网络结构和卷积神经网络,结合

棉花病害的种类及特点,构建识别 6 种棉花病害的模型(图 4)。该棉花病害识别模型分为卷积层、池化层、全连接层、SoftMax 分类层等 4 个层次,其中用 6 标签 SoftMax 分类层替换掉原有 VGG-16 网络中的 SoftMax 分类器,模型的激活函数为 ReLU 函数。

VGG-16 网络是通过 100 万幅图像的 ImageNet 数据库中训练而成,具备较强的深度特征学习能力,其拥有大量已训练完成的参数和权重,特别是卷积层关于图像的曲线、边缘、轮廓的特征提取具备较强的能力<sup>[31]</sup>。为避免从头训练整个网络,减少网络训练时间和提高网络训练效率,可将已训练好的 VGG-16 网络作为本模型的预训练模型,通过微调迁移学习的方式,将预训练的模型参数“迁移”到本研究模型,利用预训练模型的参数优化卷积层的模型参数,解决棉花病害的分类与识别问题。

VGG-16 的权重参数数量为  $65 \times 10^6$  个,其中 3 个全连接层参数集中度较高,VGG-16 的参数是为 1 000 个分类类别而设计的,而本研究只针对 6 个类别的分类。因此,提出用 2 个全连接层替换原有的 3 个全连接层,第 1 个全连接层为 4 096 个,第 2 个全连接层为 6 个,以提高模型的识别精度和效率。

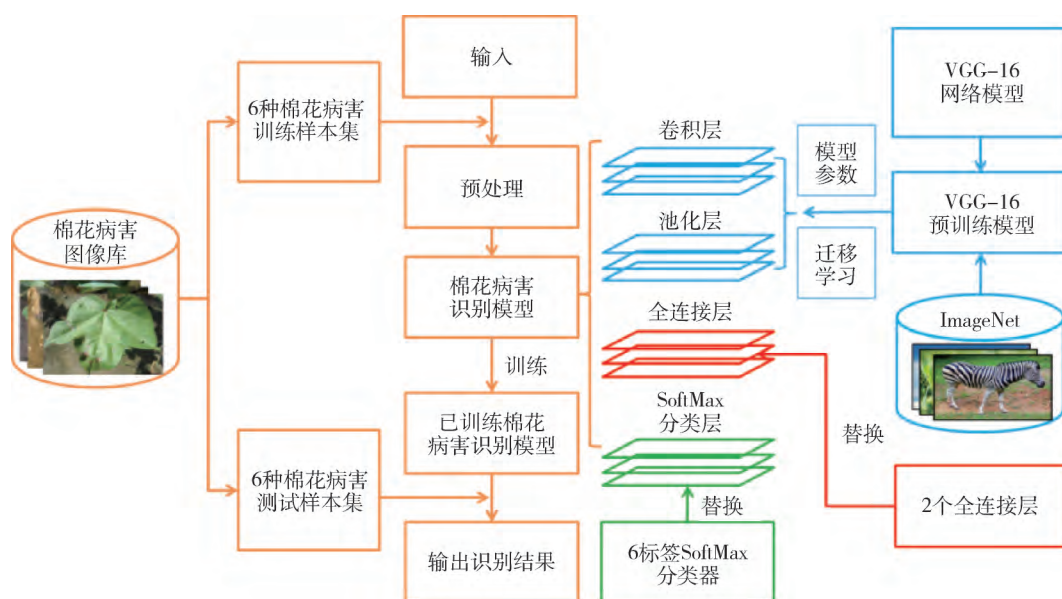


图 4 棉花病害识别模型框架

Fig. 4 Cotton disease identification model framework

棉花病害识别模型框架(图4)主要利用通过微调迁移学习将VGG-16预训练的模型参数迁移至棉花病害识别模型的卷积层、池化层和全连接层,并用6标签SoftMax分类器替换原有的SoftMax分类层。主要操作流程如下:

1)输入棉花病害样本。随机从棉花病害图像库中抽取一定等比例的6种棉花病害图片,作为训练样本集进行输入。

2)预处理。为尽可能去掉噪声并保留棉花病害的细节信息,对输入的棉花病害训练图像进行 $3\times 3$ 模板大小的高斯滤波,再进行缩放和裁剪操作,使输入图像标准化至一致分辨率大小。

3)构建棉花病害识别模型。基于VGG-16网络模型,优化全连接层,从3个优化为2个,用6标签SoftMax分类器替换原有的SoftMax分类层。

4)微调迁移学习。用VGG预训练模型参数通过迁移学习方式优化棉花病害识别模型参数,主要确定13个卷积层和池化层的参数。

5)模型训练。利用随机法初始化模型参数,设定动量参数、学习速率和训练时间,通过损失函数的迭代,冻结13个卷积层和池化层的参数,训练2个全连接层和SoftMax分类层的参数,以优化这2个层的参数。

6)模型测试。从棉花病害图像库中抽取余下的6种棉花病害图片,作为测试样本集进行模型测试,以验证模型的精确度和速度。

## 2 试验结果与分析

对棉花病害识别模型进行了仿真与试验,在一台配置有1个NVIDIA tesla K20 GPU,2个CPU为Intel Xeon E5-2620 V4 2.1G/8核16线程,4个内存为16GB DDR4存储器的深度学习工作站,该工作站还安装有Matlab2017a仿真软件和Windows 10操作系统,用以开展相关的模型训练与测试试验。相关试验包括3部分,分别是棉花病害的特征提取试验、不同样本数量和分辨率大小对模型训练与测试试验、与其他识别模型的对比试验。

### 2.1 棉花病害的特征提取试验

采用微型迁移学习将预训练模型中的卷积层和池化层参数,迁移至棉花病害识别模型中,使得棉花病害识别模型的卷积层不需要再训练,确定了卷积层的参数。第1卷积层和第2卷积层各包含2个卷

积特征提取器和2个Relu激活函数,第3至5卷积层各包含3个卷积特征提取器和3个Relu激活函数。以1幅褐斑病棉花病害叶片图像为例(图5(a)),图像经过高斯滤波处理后(图5(b)),输入棉花病害识别模型的卷积层,进行卷积层的特征提取试验,第1层卷积层和第5层卷积层提取到的特征图像见图5(c)~(e)。

由图5(c)可知,棉花病害叶片经过Conv1-1处理后得到64个特征图,由特征图可以看出Conv1-1卷积特征提取器主要提取到边缘和细节信息。从卷积特征图像可以看到,当卷积核为水平方向时,提取到棉花病叶水平边缘信息,当卷积核为垂直方向时,提取到棉花病叶垂直边缘信息。也可以看出,通过卷积运算后,棉花的病害特征信息更加突出。从图5(d)可知,通过Relu1-1激活函数处理,卷积后的棉花病害特征图边缘信息和细节信息更加明显,背景和目标区域更容易区分。

从图5(e)可知,棉花病害叶片经过Conv5-1处理后得到512个特征图,由特征图可以看出Conv5-1卷积特征提取器比Conv1-1卷积特征提取器提取到更多方向的边缘信息。从图5(f)可知,消除了棉花病害图像内部平滑信息,更加凸显多方向的棉花局部信息,使得病斑区域的形状和纹理信息更加具有可区分性。

因此,通过堆叠不同的卷积核和设置不同的卷积参数,可以获得不同层级和凸显区域的特征图,经过卷积核处理越多,获得的棉花病害特征信息越多,对病害目标的属性表达更充分和全面。

### 2.2 棉花病害识别模型训练试验

从棉花病害图像库中,随机抽取病害图像70%作为棉花病害训练集共计3856幅,其中褐斑病640幅、炭疽病588幅、黄萎病679幅、枯萎病637幅、轮纹病612幅、正常叶片700幅,另外30%棉花病害图像样本作为测试集。由于模型的卷积层已经通过迁移学习获取了VGG-16预训练模型的参数,因此,本次训练首先冻结卷积层,主要训练全连接层和SoftMax分类层的参数,通过逐层的反向操作,结合线性和非线性运算,最后训练得到全连接层的参数以及SoftMax层的多分类向量值和损失函数的值。

训练棉花病害识别模型时,采用随机梯度下降方法进行优化,设定动量参数为固定值0.9,初始学习率为100,学习率调整因子设置为0.96,迭代次数

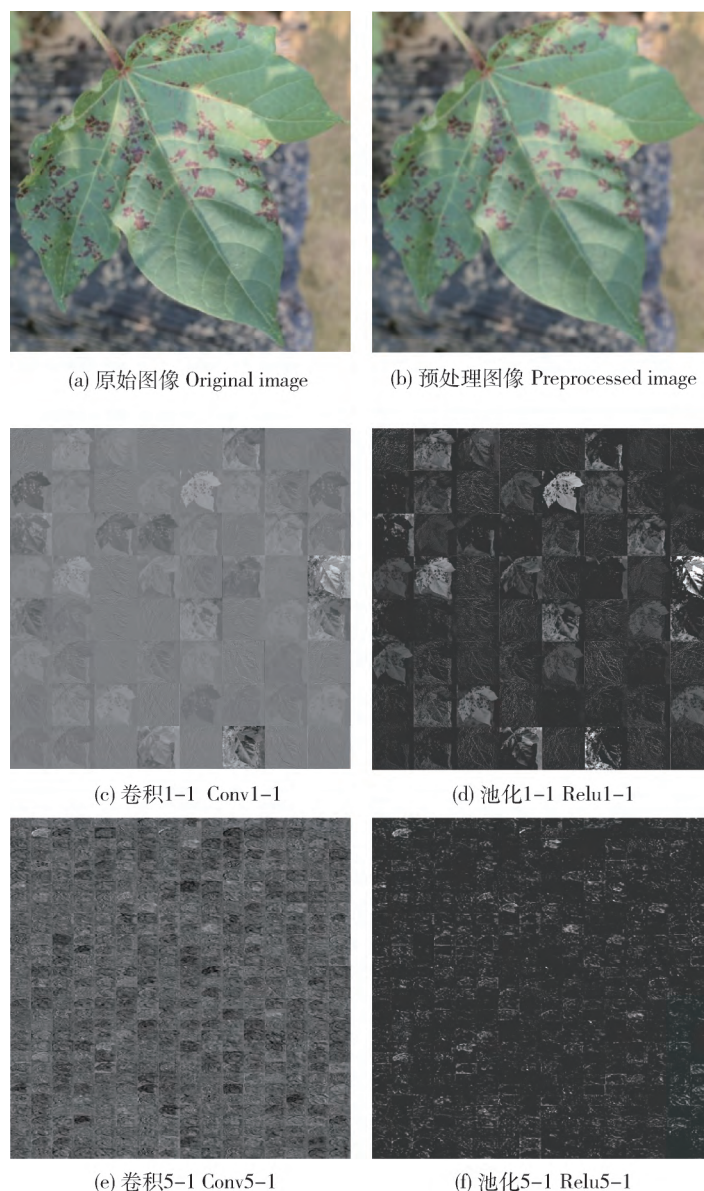


图 5 不同卷积与池化层棉花病害叶片特征提取结果

Fig. 5 Cotton disease leaf feature extraction result in Different convolution and pooling layers

设定为 5 000 次。通过随机方法对全连接层和 SoftMax 分类层的参数进行初始化,选择识别准确率作为模型训练的评价指标。

将棉花病害图像分辨率分别缩放至 128 像素 $\times$ 128 像素、256 像素 $\times$ 256 像素、512 像素 $\times$ 512 像素、768 像素 $\times$ 768 像素等 4 种,将缩放后的图像作为样本输入棉花病害识别模型中进行训练,用以筛选出最适合棉花病害分辨率大小。分别以损失函数值和识别准确率为目标,测试不同分辨率大小图像

样本的表现结果见图 6 和图 7。

随着迭代次数的增加,不同分辨率图像样本训练时的损失函数值都在不同程度的收敛(图 6)。128 像素 $\times$ 128 像素分辨率图像在迭代 4 000 次时,损失函数值降低为 0.000 208,而在 5 000 次迭代时上升至 0.000 287。256 像素 $\times$ 256 像素分辨率图像的损失函数收敛类似于 128 像素 $\times$ 128 像素分辨率图像,迭代 5 000 次时为 0.000 097。512 像素 $\times$ 512 像素分辨率图像的损失函数经过 5 000 次迭代后损



失函数值收敛至  $6.65 \times 10^{-5}$ 。768 像素  $\times$  768 像素分辨率图像经过 5 000 次迭代后,其损失函数值为 0.000 102。

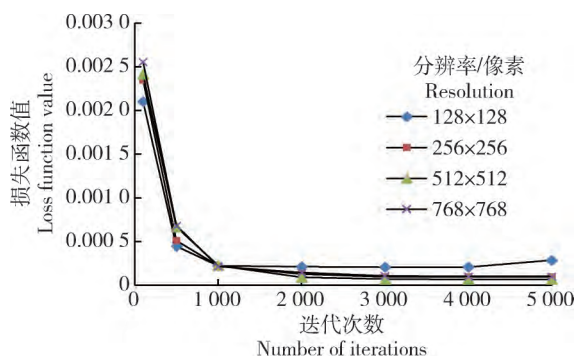


图6 不同分辨率样本的训练损失函数

Fig. 6 Training loss function values for different resolution samples

从图7可以看出,迭代次数低于正常次数时,卷积神经网络的学习不够,最后的识别准确率结果也不理想。随着迭代次数增加,不同分辨率图像在验证集的识别准确率都出现快速提升,但不同分辨率图像提高程度各有差异:128 像素  $\times$  128 像素图像经过 4 000 次迭代时其值最高达到 81%,在 5 000 次迭代时降低至 80%;256 像素  $\times$  256 像素图像在 100 次迭代后识别准确率为 35%,在 4 000 次迭代后识别准确率为 85%;512 像素  $\times$  512 像素图像在 2 000 次迭代后逐渐超越其他分辨率图像,最高时达到 91%;768 像素  $\times$  768 像素图像在不同迭代次数的表现同于 512 像素  $\times$  512 像素图像,识别准确率为 91%。

从不同分辨率大小图像在不同迭代次数的损失

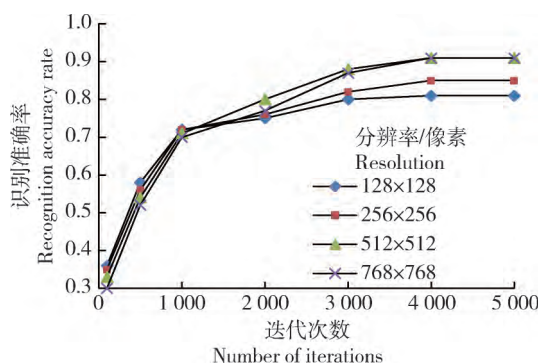


图7 不同分辨率样本的识别准确率

Fig. 7 Recognition accuracy for different resolution samples

函数值与平均识别准确率的表现看出,512 像素  $\times$  512 像素图像样本在 4 种分辨率图像样本中表现最好,相较于其他分辨率大小更适合棉花病害图像的识别。从训练次数角度看,在一定程度下,迭代次数越多,模型的识别准确率越高,而超过一定的程度,网络模型的识别正确率不会再继续提高,有可能还会出现一定幅度的降低。因此,选择合适的迭代次数可以获得更优异的网络模型参数,从棉花病害识别模型训练试验看,训练 4 000 次可以获得较好的训练效果。

### 2.3 棉花病害识别模型对比试验

为进一步测试本研究模型的性能,选择 BP 神经网络、支持向量机等 2 种浅层网络,以及 AlexNET、GoogleNET、VGG-16NET 等 3 种深层神经网络与本研究模型进行对比试验。从棉花病害图像库中,30%棉花病害图像样本作为测试集,分别为褐斑病 275 幅、炭疽病 252 幅、黄萎病 291 幅、枯萎病 273 幅、轮纹病 263 幅、正常叶片 300 幅,共计 1 654 幅棉花病害图像。

在浅层网络方面,BP 神经网络、支持向量机等因需要人工选定病害特征。因此,根据大量研究结果,棉花病害主要是集中在颜色信息和纹理信息,分别从 YIQ、YCbCr、HSV、YCM、Extra-RGB、RGB、HSL 等 6 个颜色空间中,选择棉花病害图像的 Y、I、Q、Cb、Cr、H、S、V、C、M、Extra-R、Extra-G、Extra-B、R、G、B、L 等 17 个颜色分量作为颜色特征;利用灰度共生矩阵获取棉花病害的纹理信息:角二阶矩、熵、对比度、逆差矩、相关度、均值、方差等 7 种提取病害图像的纹理特征。

在深层卷积网络方面,AlexNET、GoogleNET 和 VGG-16 卷积神经网络都采用标准的网络结构,具体为 AlexNET、GoogleNET 的结构为卷积层为 5 层,全连接层为 3 层,VGG-16NET 结构为 13 个卷积层和 3 个全连接。本研究模型与 BP 神经网络、支持向量机和 VGG-16 卷积神经网络的对比试验结果见表 1。

在单个病害识别准确率方面,褐斑病、炭疽病和轮纹病由于病斑大小与纹理比较相近,往往识别错误,单个病害识别准确率较其他病害低;黄萎病和枯萎病由于在染病后其叶脉和叶片边缘区域容易变色和褶皱现象,比较容易区分;正常叶片的识别准确率最高,因其相较于其他病害最容易进行识别与分类。在平均识别准确率方面,BP 神经网络、支持向量机、



AlexNET、GoogleNET、VGG-16NET 与本研究模型分别为 62.70%、65.45%、85.33%、86.12%、88.75%、89.51%，从结果可以看出，AlexNET、GoogleNET、VGG-16NET 与本研究模型等 4 种深层神经网络模型大幅优于 BP 神经网络、支持向量机等浅层神经网络，平均识别准确率高出 20% 以上。在深层神经网络模型中，由于 VGG-16NET 模型和本研究模型的特征提取是通过  $3 \times 3$  滤波

器的组合与堆叠，提取出病害区域内更多非常细小的特征，因此，VGG-16NET 模型和本研究模型优于 AlexNET 和 GoogleNET；同时，本研究模型减少了全连接层数量，并设计了针对 6 标签的 SoftMax 分类器，在测试集中略优于 VGG-16NET 模型。从测试结果看，与其他模型相比本研究模型具有更高的识别准确率，能更好识别棉花病害类别。

表 1 棉花病害识别模型测试结果

Table 1 Cotton disease identification model test results

%

识别模型 Recognition model	单个病害识别准确率 Accuracy rate of individual disease identification						平均识别准确率 Average recognition accuracy
	褐斑病 <i>Cercospora</i> leaf spot	炭疽病 <i>Anthraco</i> nose	黄萎病 <i>Verticillium</i> wilt	枯萎病 <i>Fusarium</i> wilt	轮纹病 Wheel disease	正常叶片 Health leaf	
BP 神经网络 BP neural network	61.91	59.16	62.67	61.86	59.81	70.81	62.70
支持向量机 Support vector machine	66.53	62.13	65.15	63.19	62.06	73.68	65.45
AlexNET	86.39	82.55	81.44	86.32	83.46	91.81	85.33
GoogleNET	88.55	82.69	86.71	84.11	82.60	92.07	86.12
VGG-16NET	86.74	85.95	89.44	89.79	87.35	93.22	88.75
本研究模型 Proposed model	87.85	86.61	89.37	90.77	88.91	93.54	89.51

### 3 结 论

本研究在 VGG-16 卷积神经网络基础上，用 2 个全连接层替换原有的 3 个全连接层，并用 6 标签 SoftMax 分类层替换原有 VGG-16 网络中的 SoftMax 分类器，对褐斑病、炭疽病、黄萎病、枯萎病、轮纹病与正常叶片等 6 种棉花病害进行训练与识别试验，得到以下结论：

1) 棉花病害的特征提取试验结果表明，通过微型迁移学习实现了识别模型卷积层与池化层的权值参数分享，减少了网络的训练参数，能有效提取出棉花病害叶片图像的多层特征图像，并通过 Relu 激活函数的处理更能凸显棉花病害的边缘信息与纹理信息，为后续分类识别提供特征信息。

2) 棉花病害识别模型训练试验结果表明，图像分辨率大小对不同迭代次数的损失函数值与平均识

别准确率有不同程度影响，试验表明  $512 \text{ 像素} \times 512 \text{ 像素}$  分辨率图像在 4 种分辨率图像样本中表现最好。从训练次数角度看，在一定范围内，迭代次数越多，模型的识别准确率越高，而超过一定范围，网络模型的识别正确率不会再继续提高，有可能还会出现一定幅度的降低。

3) 棉花病害识别模型对比试验结果表明，深层网络模型优于浅层网络模型，与 BP 神经网络、支持向量机浅层网络比较，深层神经网络平均识别准确率高出 20% 以上。由于通过  $3 \times 3$  滤波器的组合与堆叠获得病害区域内更多非常细小的特征，本研究模型和 VGG-16NET 优于 AlexNET 和 GoogleNET。从测试结果看，本研究模型略优于 VGG-16NET 模型，对棉花病害类别具有更好的分类性能。

4) 本研究模型是在 6 类棉花病害图像库共计 5 510 幅图像进行训练与测试，在今后的研究中继续

采集棉花病害叶片图像,扩大棉花病害库的数量与种类,增加训练样本,特别是增加不同气象条件、不同拍摄角度、不同危害程度的棉花叶片,将复杂自然条件下的棉花病害叶片用于模型训练,进一步提高棉花病害识别性能。

5)本研究模型是在 VGG 卷积神经网络的全连接层进行改进,后期需加大对模型的卷积层和池化层的结构的优化,进一步优化模型的网络结构,加强模型对于棉花病害特别是病斑的特征提取。

## 参考文献 References

- [1] 戴建国, 赖军臣. 基于图像规则与 Android 手机的棉花病虫害诊断系统[J]. 农业机械学报, 2015, 46(1):35-44  
Dai J G, Lai J C. Image-rule-based diagnostic expert system for cotton diseases and pests based on mobile terminal with android system[J]. *Transactions of the Chinese Society for Agricultural Machinery*, 2015, 46(1):35-44 (in Chinese)
- [2] 李凯, 张建华, 冯全. 复杂背景与天气条件下的棉花叶片图像分割方法[J]. 中国农业大学学报, 2018, 23(2):88-89  
Li K, Zhang J H, Feng Q. Image segmentation method for cotton leaf under complex background and weather conditions [J]. *Journal of China Agricultural University*, 2018, 23 (2):88-89 (in Chinese)
- [3] 张建华, 冀荣华, 祁力钧. 基于径向基支持向量机的棉花虫害识别[J]. 农业机械学报, 2011, 42(8):192-197  
Zhang J H, Ji R H, Qi L J. Recognition of pest damage for cotton leaf based on RBF-SVM algorithm[J]. *Transactions of the Chinese Society for Agricultural Machinery*, 2011, 42 (8): 192-197 (in Chinese)
- [4] Zhang J H, Kong F T, Zhai Z F. Robust image segmentation method for cotton leaf under natural conditions based on immune algorithm and PCNN algorithm [J]. *International Journal of Pattern Recognition & Artificial Intelligence*, 2017, 32(5):1-18
- [5] Mishra P, Shahrimie M, Asaari M. Close range hyperspectral imaging of plants: A review [J]. *Biosystems Engineering*, 2017, 164(6):49-67
- [6] Camargo A, Smith J S. An image-processing based algorithm to automatically identify plant disease visual symptoms[J]. *Biosystems Engineering*, 2013, 1(4):9-21
- [7] Barbedo J G A, Koenigkan L V, Santos T T. Identifying multiple plant diseases using digital image processing [J]. *Biosystems Engineering*, 2016, 147(8):104-116
- [8] Wang D, Tan X. Unsupervised feature learning with C-SVDDNet[J]. *Pattern Recognition*, 2016, 60:473-485
- [9] Shi Y, Huang W, Luo J. Detection and discrimination of pests and diseases in winter wheat based on spectral indices and kernel discriminant analysis[J]. *Computers & Electronics in Agriculture*, 2017, 141(5):171-180
- [10] Phadikar S, Sil J, Das A K. Rice diseases classification using feature selection and rule generation techniques [J]. *Computers & Electronics in Agriculture*, 2013, 90(8):76-85
- [11] Camargo A, Smith J S. Image pattern classification for the identification of disease causing agents in plants [J]. *Computers and Electronics in Agriculture*, 2009, 66(1): 121-125
- [12] Phadikar S, Sil J, Das A K. Rice diseases classification using feature selection and rule generation techniques [J]. *Computers & Electronics in Agriculture*, 2013, 90(90): 76-85
- [13] Zhang S, You Z, You Z. Leaf image based cucumber disease recognition using sparse representation classification [J]. *Computers & Electronics in Agriculture*, 2017, 134(1): 135-141
- [14] Barbedo J G A, Koenigkan L V, Santos T T. Identifying multiple plant diseases using digital image processing [J]. *Biosystems Engineering*, 2016, 147:104-116
- [15] Chung C L, Huang K J, Chen S Y. Detecting Bakanae disease in rice seedlings by machine vision [J]. *Computers & Electronics in Agriculture*, 2016, 121(3):404-411
- [16] 张建华, 祁力钧, 冀荣华. 基于粗糙集和 BP 神经网络的棉花病害识别[J]. 农业工程学报, 2012, 28(7):161-167  
Zhang J H, Qi L J, Ji R H. Cotton diseases identification based on rough sets and BP neural network[J]. *Transactions of the Chinese Society of Agricultural Engineering*, 2012, 28(7): 161-167 (in Chinese)
- [17] Zhou R, Kaneko S, Tanaka F, Kayamori M, Shimizu M. Disease detection of Cercospora Leaf Spot in sugar beet by robust template matching[J]. *Computers & Electronics in Agriculture*, 2014, 108(4):58-70
- [18] 黄双萍, 孙超, 齐龙. 基于深度卷积神经网络的水稻穗瘟病检测方法[J]. 农业工程学报, 2017, 33(20):169-176  
Huang S P, Sun C, Qi L. Rice panicle blast identification method based on deep convolution neural network [J]. *Transactions of the Chinese Society of Agricultural Engineering*, 2017, 33(20):169-176 (in Chinese)
- [19] Cheng X, Zhang Y, Chen Y. Pest identification via deep residual learning in complex background [J]. *Computers & Electronics in Agriculture*, 2017, 141:351-356
- [20] Lu J, Hu J, Zhao G. An in-field automatic wheat disease diagnosis system [J]. *Computers & Electronics in Agriculture*, 2017, 142:369-379
- [21] 李政, 李永树, 吴玺. 基于卷积神经网络的空心村高分影像建筑物检测方法[J]. 农业机械学报, 2017(9):160-165  
Li Z, Li Y S, Wu X. Building Interpretation model of hollow village high resolution images based on bag-of-words [J].

- Transactions of the Chinese Society for Agricultural Machinery*, 2017(9):160-165 (in Chinese)
- [22] 高震宇, 王安, 刘勇, 张龙, 夏营威. 基于卷积神经网络的鲜茶叶智能分选系统研究[J]. *农业机械学报*, 2017, 48(7): 53-58
- Gao Z Y, Wang A, Liu Y, Zhang L, Xia Y W. Intelligent fresh-tea-leaves sorting system research based on convolution neural network[J]. *Transactions of the Chinese Society for Agricultural Machinery*, 2017, 48(7): 53-58 (in Chinese)
- [23] Girshick R, Donahue J, Darrell T. Region-based convolutional networks for accurate object detection and segmentation[J]. *IEEE Transactions on Pattern Analysis & Machine Intelligence*, 2016, 38(1): 142-158
- [24] 李敬. 基于卷积神经网络的烟草病害自动识别研究[D]. 泰安: 山东农业大学, 2016
- Li J. Automatic identification research of tobacco diseases based on convolutional neural network[D]. Taian: *Shandong Agricultural University*, 2016 (in Chinese)
- [25] Xie G S, Zhang X Y, Yang W. LG-CNN: From local parts to global discrimination for fine-grained recognition [J]. *Pattern Recognition*, 2017, 71: 118-131
- [26] Cheng X, Zhang Y, Chen Y. Pest identification via deep residual learning in complex background[J]. *Computers & Electronics in Agriculture*, 2017, 141: 351-356
- [27] Gopalakrishnan K, Khaitan S K, Choudhary A. Deep convolutional neural networks with transfer learning for computer vision-based data-driven pavement distress detection [J]. *Construction & Building Materials*, 2017, 157: 322-330
- [28] Manuel L A, Ruben G O, Nicolai P. Appearance-invariant place recognition by discriminatively training a convolutional neural network[J]. *Pattern Recognition Letters*, 2017, 92: 89-95
- [29] 周云成, 许童羽, 郑伟, 邓寒冰. 基于深度卷积神经网络的番茄主要器官分类识别方法[J]. *农业工程学报*, 2017, 33(15): 219-226
- Zhou Y C, Xu T Y, Zhen W, Deng H B. Classification and recognition approaches of tomato main organs based on DCNN [J]. *Transactions of the Chinese Society of Agricultural Engineering*, 2017, 33(15): 219-226 (in Chinese)
- [30] Liu H, Lu J, Feng J. Group-Aware deep feature learning for facial age estimation[J]. *Pattern Recognition*, 2017, 66(C): 82-94
- [31] Feng L, Po L M, Li Y. Integration of image quality and motion cues for face anti-spoofing: A neural network approach [J]. *Journal of Visual Communication & Image Representation*, 2016, 38(23): 451-460

责任编辑: 刘迎春