



计算机工程与应用  
Computer Engineering and Applications  
ISSN 1002-8331,CN 11-2127/TP

## 《计算机工程与应用》网络首发论文

题目: 基于改进的卷积神经网络脑电信号情感识别  
作者: 田莉莉, 邹俊忠, 张见, 卫作臣, 汪春梅  
网络首发日期: 2018-12-21  
引用格式: 田莉莉, 邹俊忠, 张见, 卫作臣, 汪春梅. 基于改进的卷积神经网络脑电信号情感识别[J/OL]. 计算机工程与应用.  
<http://kns.cnki.net/kcms/detail/11.2127.tp.20181218.1902.044.html>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

# 基于改进的卷积神经网络脑电信号情感识别

田莉莉<sup>1</sup>, 邹俊忠<sup>1</sup>, 张 见<sup>1</sup>, 卫作臣<sup>1</sup>, 汪春梅<sup>2</sup>

TIAN Lili<sup>1</sup>, ZOU Junzhong<sup>1</sup>, ZHANG Jian<sup>1</sup>, WEI Zuochen<sup>1</sup>, WANG Chunmei<sup>2</sup>

1.华东理工大学 信息科学与工程学院 自动化系, 上海 200237

2.上海师范大学 信息与机电工程学院 自动化系, 上海 200234

1.Department of Automation, School of Information Science and Engineering, East China University of Science and Technology, Shanghai 200237, China

2.Department of Automation, School of Information Mechanical and Electrical Engineering, Shanghai Normal University, Shanghai 200234, China

**TIAN Lili, ZOU Junzhong, ZHANG Jian, et al. Emotion Recognition of EEG Signal Based on Improved Convolutional Neural Network. Computer Engineering and Applications**

**Abstract:** Considering that traditional machine learning requires artificial construction features and low feature quality, this paper proposes a novel automatic feature extraction approach in electroencephalograph (EEG) signals based on 1-D convolutional neural network (CNN). In this study, this paper uses the idea of compilation, at the same time the convolutional layer and the down sampling layer form the encoder network to extract the emotional characteristics of the EEG signal, and then the Leaky ReLU activation function is applied to the feature map. For the convolution pre-training process, the cross-entropy and regularization terms are used to optimize the loss function, and then the random forest classifier is used to obtain the emotion classification label. Finally, the experiment was carried out on the international public data set SEED, which achieved 94.7% sentiment classification accuracy and the experimental results show the effectiveness and robustness of the proposed method.

**Key words:** EEG; feature extracting; CNN; random forest; loss function

**摘 要:** 针对传统机器学习需要人工构建特征及特征质量较低等问题, 提出一种新颖的基于一维卷积神经网络(Convolutional Neural Network, CNN)的特征提取方法。采用编码思想, 由卷积层和下采样层构成编码器网络提取脑电信号情感特征, 随后与特征图一起输入 Leaky ReLU 激活函数。对于卷积预训练过程使用交叉熵和正则化项双目标优化损失函数, 之后采用随机森林分类器以获得情感分类标签。最终在国际公开数据集 SEED 上进行实验, 达到 94.7% 的情感分类准确率, 实验结果表明该方法的有效性和鲁棒性。

**关键词:** 脑电信号; 特征提取; 卷积神经网络; 随机森林; 损失函数

文献标志码: A 中图分类号: TP391 doi: 10.3778/j.issn.1002-8331.1807-0219

## 1 引言

情感在人们的日常生活和认知中扮演着重要的角色。目前情感识别研究已经成为脑机接口、人工智能、计算机科学及医疗健康等领域的热门话题, 特别是用于辅助精神病和心理障碍等疾病产生的机理和发作规

律的研究治疗上。

早期的情感研究主要是利用面部表情和语调来识别, 后来利用脉搏、呼吸等外围生理信号, 其中脑电图信号因其较高的准确性和客观性备受情感识别研究者的青睐。AayushBhadwaj<sup>[1]</sup>等人使用支持向量机

**基金项目:** 国家自然科学基金资助项目(No.61071085)。

**作者简介:** 田莉莉(1992-), 女, 硕士研究生, 研究领域为模式识别与智能系统, 脑电信号处理, E-mail: 1547772448@qq.com; 邹俊忠(1960-), 男, 博士, 教授, 研究领域为人工智能与模式识别应用、脑电波信号处理与人性化护理机器人研究; 张见(1976-), 男, 博士, 工程师, 研究领域为模式识别; 汪春梅(1960-), 女, 博士, 副教授, 研究领域为通信信号处理与模式识别。

(Support Vector Machine, SVM)和线性判别分析(Linear Discriminant Analysis, LDA)两种算法,采用 EEG 信号识别七种情绪得到平均总准确率分别为 74.13%和 66.50% ; Yazdani<sup>[2]</sup>等人利用贝叶斯线性判别分析,针对六类情绪(喜悦、愤怒、厌恶、悲伤、惊讶、恐惧)进行了分类,最终达到 80% 以上的准确率; Murugappan<sup>[3]</sup>等人借助离散小波变换(Discrete Wavelet Transform, DWT)将 EEG 信号分解为三个频段,结合 k-近邻算法(k-Nearest Neighbor, KNN)实现了 83.26%的准确率。虽然传统的人工提取情感特征结合机器学习相关算法取得了较好的发展,但是以上传统的方法大都需要大量先验知识寻找脑电信号的特征,构建特征工程,而脑电信号容易受到噪声干扰,且不同被试之间的差异性,使得基于脑电信号人工特征选取耗费大量的时间和精力。

近年深度学习因其能够深层挖掘数据更本质的特征受到了越来越多研究者的关注。深度学习起源于神经网络,通过在神经网络的输入与输出层之间添加多级网络层结构,实现输入信息的分级表达,完成神经网络从浅层学习到深度学习的转变,提高神经网络对数据的处理能力。深度卷积神经网络是深度学习领域中广泛应用的一种结构,通过对简单节点进行非线性组合,使其具有高度的概括能力。1989 年 LeCun 等<sup>[4]</sup>采用误差梯度算法训练卷积神经网络,在手写数字识别中取得最好效果;2012 年 Krizhevsky 等<sup>[5]</sup>采用 Alex Net 的卷积神经网络在 ImageNet 竞赛图像分类任务中取得优异的成绩,使得卷积神经网络越来越受研究者的重视。

结合卷积神经网络在图像视觉领域的突出表现,针对传统人为设计特征的不足,将其在脑电信号的情感识别领域进行了研究,其创新点在于:

(1) 传统的人工特征提取方法耗费大量的时间,本文结合脑电信号时间和空间上的联系,提出的一维卷积神经网络随机森林(Random forest, RF)情感识别的方法可以直接从原始数据中获取信息,省去了繁琐的特征工程这一步骤,并且一次特征提取就可以达到 94.7%的分类正确率,表明在较少训练样本的条件下可以达到很理想的识别效果;

(2) 损失函数设计选取交叉熵函数<sup>[6]</sup>和 L2 正则化项<sup>[7]</sup>损失函数结合,实现卷积神经网络的权值更新算法;

(3) 针对卷积神经网络中 Relu 激活函数阈值为负时神经元丢弃的缺陷,设计选择 Leaky Relu 作为卷积神经网络的激活函数。

## 2 方法与模型

### 2.1 深度卷积神经网络

与传统的特征提取方法不同,卷积神经网络能在训练数据的驱动下自适应地构建特征描述,挖掘高水平的特征,从而提高分类任务的效果。卷积神经网络与普通神经网络的区别在于,卷积神经网络主要包含了卷积层(Convolutional Layer)和池化层(Pooling Layer)构成的特征抽取器<sup>[8]</sup>。

卷积层的作用是对上一层的输入进行多个核卷积,之后作为激励函数的输入得到下一个输出的特征,其计算公式为:




图1 设计的 CNN 结构图

$$x_j^l = f \left( \sum_{i \in M_j} x_i^{l-1} * k_{ij}^l + b_j^l \right) \quad (1)$$

其中,  $x_j^l$  表示第  $l$  层的第  $j$  个特征,  $k_{ij}^l$  表示第  $l$  层的第  $j$  个特征与第  $l-1$  层的第  $i$  个特征的连接权值。  $b_j^l$  表示对应的偏置。“\*”表示卷积操作。

对于卷积神经网络经过卷积操作后的特征图大小计算公式如下:

$$out_{length} = \frac{(in_{length} - f_{length} + 2P)}{stride_{length}} + 1 \quad (2)$$

$$out_{width} = \frac{(in_{width} - f_{width} + 2P)}{stride_{width}} + 1 \quad (3)$$

其中  $out_{length}$  和  $out_{width}$  分别表示卷积之后输出矩阵的长与宽,  $in_{width}$  和  $in_{length}$  分别表示卷积前的输入矩阵的宽与长,  $f_{length}$  和  $f_{width}$  分别表示卷积核的长与宽,  $P$  表示 padding 操作过程中需要填充的 0 的个数,  $stride_{length}$  和  $stride_{width}$  分别表示水平方向的滑动步长和垂直方向的滑动步长。

池化层的作用即对卷积层的特征图进行下采样 (Down sampling), 降低了网络的维度。目前卷积神经网络中较为常用的池化操作为最大池化 (Max-pooling)

和平均池化 (Average pooling)。降采样表达式如下:

$$x_j^l = f(\beta_j^l bool(x_j^{l-1}) + b_j^l) \quad (4)$$

其中  $bool(\cdot)$  表示降采样函数, 经过降采样的值与偏执系数  $\beta$  相乘, 之后由激活函数输出该值。

经典的卷积神经网络模型设计中, 开始几层通常是卷积层和下采样层的交替, 在靠近输出层的最后几层网络通常是全连接网络。此外网络深度很大程度影响着最终的分类精度, 基于上述设计原则, 同时参考 Krizhevsky<sup>[9]</sup>等人提出的经典 AlexNet 模型, 设计了一个卷积编码深度神经网络, 其中卷积神经网络结构设计见图 1。改进的神经网络主要由卷积层、池化层、全连接层构成, 之后全连接层连接随机森林分类器作为输出层, 最终设计了一个 8 层卷积编码神经网络结构。为保证各个环节输入数据分布一致, 本文在全连接层和激活函数层之间进行了批归一化<sup>[10]</sup>数据处理, 同时加入 Dropout 策略<sup>[11]</sup>防止网络训练过拟合。

目前对于 CNN 超参数的设置, 还是只能依靠人工实验多次确定最优结果, 本文多次尝试之后, 确定了最终的 CNN 超参数设置, 见表 1。

表 1 CNN 超参数

层	类型	特征图	步长	卷积核	池化
1	输入	62×200×1	-	-	-
2	卷积	32@62×40	长: 1 宽: 5	5×5×1	-
3	批归一化	32@62×40	-	-	-
4	池化	32@62×40	长: 1 宽: 1	-	2×2
5	卷积	64@62×20	长: 1 宽: 2	3×3×32	-
6	批归一化	64@62×20	-	-	-
7	池化	64@62×20	长: 1 宽: 1	-	2×2
8	卷积	128@62×10	长: 1 宽: 2	1×1×64	-
9	批归一化	128@62×10	-	-	-
10	池化	128@62×10	长: 1 宽: 1	-	2×2
11	全连接	128@1×1	-	-	-
12	全连接	1024@1×1	-	-	-
13	输出	3@1×1	-	-	-

## 2.2 Adam 参数学习算法

针对深度卷积神经网络优化训练过程, 本文采用一种自适应参数的方法 Adam 算法<sup>[12]</sup>。Adam 可以对梯度损失函数进行优化, 且能在低冲量的情况下自适应的更新连接权值。Adam 有一个呈指数衰减的过去时刻梯度:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (5)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (6)$$

其中  $m_t$  表示梯度第一动量的估计值,  $v_t$  表示梯度第二动量的估计值, 初始值均为 0。

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (7)$$



$$\hat{v}_t = \frac{v_t}{1 - \beta_2'} \quad (8)$$

参数更新公式为：

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \varepsilon} \hat{m}_t \quad (9)$$

### 2.3 Leaky Relu 激活函数

激活函数主要用来加入非线性因素，提供网络的非线性建模能力，使得深度网络具有非线性映射性。目前，常见的激活函数多是分段线性和具有指数形状的非线性函数。修正线性单元( Rectified Linear Units, ReLU ) 是近几年最受欢迎的激活函数，被定义为：

$$f(x) = \begin{cases} x, & \text{if } x \geq 0 \\ 0, & \text{if } x < 0 \end{cases} \quad (10)$$

可以看到当  $x < 0$ ，ReLU 硬饱和， $x > 0$ ，ReLU 则不存在饱和问题，因此，ReLU 可以在  $x > 0$  时保持梯度不衰减，从而缓解梯度消失问题，确保以监督的方式训练神经网络，但是，随着训练的递进，部分输入会落入硬饱和区，导致相关权重无法更新，即“神经元死亡”，针对此现象，提出了改进的 ReLU 激活函数 Leaky-ReLU<sup>[13]</sup>。LReLU 是对 ReLU 进一步的限制，其定义如下：

$$f(x) = \begin{cases} x, & \text{if } x \geq 0 \\ \alpha x, & \text{if } x < 0 \end{cases} \quad (11)$$

### 2.4 Dropout

Dropout 的提出是为了防止过拟合。Dropout 策略是以一定的概率(Dropout ratio)将隐藏层神经元的输入、输出设置为零，即按照一定的概率将其暂时从网络中丢弃，注意丢弃是暂时的，选中“dropped out”的隐藏层神经元在网络中既不参与前向传播，也不参与误差的反向传播，但是它的权重会保留下来，所以每次输入样本进行训练，该卷积神经网络就相当于采用了与先前不同的网络结构，但是不同网络结构之间的权重是共享的，这等同于使用 Dropout 的功能训练出了多个模型。Dropout 一般使用在全连接层之后，由于概率为 0.5 的时候，Dropout 随机生成的网络结构最多，为此在训练过程中将其设为 0.5，而验证和测试的 Dropout 概率值均设为 1。

### 2.5 损失函数

为了提高网络模型的收敛速度，本文创造性的将交叉熵函数与 L2 正则化项进行融合，作为情感识别算法的损失函数，见(12)式。第一项是交叉熵函数，其中概率分布  $p$  为期望输出，概率分布  $q$  为实际输出，第二项是 L2 正则化项， $\lambda$  代表正则化项系数， $n$  是训练集的样本大小。

$$\text{loss} = -\sum_x p(x) \lg q(x) + \frac{\lambda}{2n} \sum_w w^2 \quad (12)$$

### 2.6 随机森林

随机森林是 Breiman<sup>[14]</sup>提出的一种基于决策树集成的非线性模型。随机森林是典型的 bagging 框架<sup>[15]</sup>的代表，在树的内部节点分裂过程中，随机抽样一部分特征纳入分枝计算，降低了子模型之间的相关程度。其基本思想是：首先采用 Bagging 方法从训练集中抽取  $k$  个样本，保证抽取的每一个样本容量都与原始训练集一样。抽样过程结束之后，针对  $k$  个样本建立  $k$  个决策树模型，经过决策得到  $k$  种分类结果，最后对上述  $k$  种分类结果每一个记录进行投票，采用多数投票集成决策的方法确定最终的分类结果，其最终决策过程可表示为：

$$H(x) = \arg \max_y \sum_{i=1} I(h_i(x) = y) \quad (13)$$

其中  $I(\cdot)$  表示示性函数，其取值范围为 0 到 1， $H(x)$  表示组合分类模型， $h_i$  代表单个决策树分类模型， $Y$  代表输出变量。

随机森林的边际函数定义为：

$$\text{mr}(X, Y) = P(h(X, \theta) = Y) - \max_{j \neq Y} P(h(X, \theta) = j) \quad (14)$$

分类器  $\{h(X, \theta)\}$  的分类器强度  $s$  由随机森林模型边缘函数的期望表示，即：

$$s = E_{X,Y} \text{mr}(X, Y) \quad (15)$$

假设  $s \geq 0$ ，由切比雪夫不等式可得：

$$PE^* \leq \frac{\text{var}(\text{mr})}{s^2} \quad (16)$$

随机森林各决策树之间的平均相关度为：

$$\bar{\rho} \leq \frac{\text{var}(mr)}{sd(h(*))^2} \quad (17)$$

其中,  $\bar{\rho}$  是相关系数的均值, 表示随机森林中树之间的相关程度。

随机森林的泛化误差上界定义为:

$$PE^* \leq \frac{\bar{\rho}(1-s^2)}{s^2} \quad (18)$$

由(18)式可知, 随机森林的泛化误差主要取决于决策树之间的相关程度和单棵决策树的分类强度。

## 2.7 算法步骤

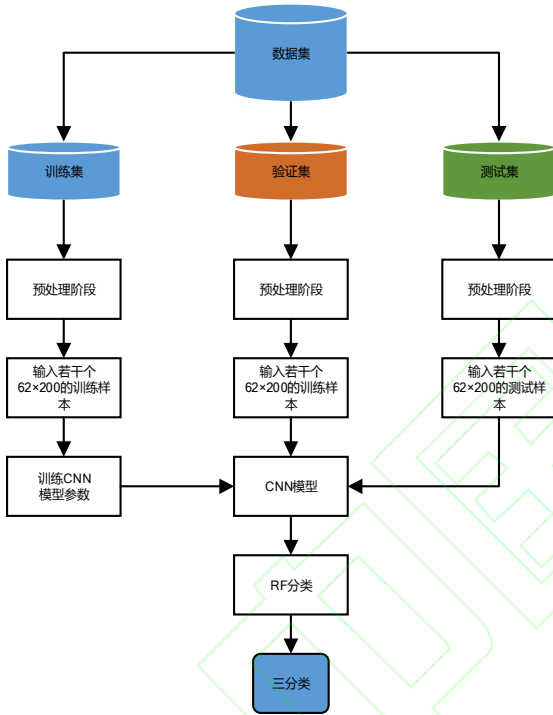


图 2 算法流程图

本研究所构建的深度卷积神经网络随机森林算法包括训练和测试两部分, 其具体的算法流程图见图 2。基本的研究思路为在特征提取一步中采用一维卷积神经网络, 而在分类识别中主要选用 RF 分类器, 这样构成的新方法可以充分发挥 CNN 的特征提取能力与 RF 的分类效果, 本文的识别方法初步可以归纳为以下四个步骤:

- (1) 预处理阶段: 首先将原始数据进行预处理和归一化, 归一化采用最大最小化法;
- (2) 网络初始化: 采用截尾高斯分布的方式对 CNN 网络权值初始化, 将其中的偏置设为常量;
- (3) 卷积神经网络特征提取阶段: 随机从训练集

抽取一个 batch 块作为训练样本, 将其作为网络结构的第一层输入, 之后经过前向传播和反向传播, 进行网络权值的更新, 逐层训练网络, 直到所有的训练样本测试结束;

(4) 随机森林分类: 将 CNN 网络的最后一层特征作为随机森林的输入, 以此分类。

需要注意的是只有在使用训练样本集的时候才去训练网络模型, 在测试和验证过程中只需要测试训练好的网络模型。

## 2.8 模型评价指标

根据 Bajic 的标准, 本文采用以下四个定量模型评估指标评价模型的性能, 即准确率 (Accuracy)、精确率 (Precision)、召回率 (Recall) 和  $F1-Measure$  [16], 定义如下:

$$(1) Accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

$$(2) Precision = \frac{TP}{TP + FP}$$

$$(3) Recall = \frac{TP}{TP + FN}$$

$$(4) F1-Measure = \frac{2TP}{2TP + FP + FN}$$

其中  $TP$  表示被模型预测为正类的正样本,  $FP$  表示被模型预测为正类的负样本,  $TN$  表示被模型预测为负类的负样本,  $FN$  表示被模型预测为负类的正样本。

## 3 实验及其分析

### 3.1 实验设计

#### 3.1.1 实验环境

实验采用的硬件设备是 Intel Core 4.2 GHz i7-7700K CPU 和 NVIDIA GeForce GTX 1080 Ti GPU。软件环境采用 Python 和 Matlab2016a, 同时借助 Google 开源的深度学习软件架构 Tensorflow<sup>[17]</sup> 搭建卷积神经网络模型。

#### 3.1.2 实验数据

本文用于情感识别的数据集是来自上海交通大学 2015 年的公开数据集 SEED<sup>[18]</sup>。SEED 数据集的诱发材料为中文电影的情感片段。在一次实验中总共有 15

个片段，每一个片段都持续 4 分钟左右。电影片段分为三种类型的情绪(积极的、中立的、消极的)。每一种情感都有五个相应的电影情感片段。每个被试均由艾克森人格问卷筛选，最终选出了 15 名 ( 7 名男性和 8 名女性 ) 平均年龄 23 岁左右的被试。每位被试在观看每个电影片段前有 5S 的提示，观看结束后，被要求完成一项 45S 反映他们真实情感的自我评估，之后休息 15S 观看下一个视频，实验流程如图 3。

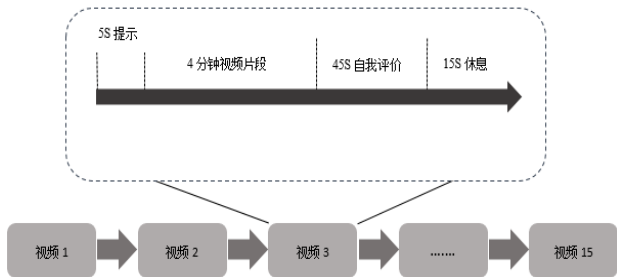


图 3 实验过程

每名被试参加 3 次实验，实验间隔为一周左右，该数据集包含 62 个通道的脑电图记录值，根据国际 10-20 标准系统<sup>[19]</sup>，从 ESI 神经扫描系统获得。将原始信号采样率为 1000 Hz 降采样至 200Hz，之后经过 0.5-70Hz 带通滤波，同时对 EEG 数据进行可视化检查，从数据集手动删除严重污染的数据记录，得到预处理后的数据集。

3.1.3 样本集划分

本文划分数据集之前对每个被试的样本进行随机打乱操作，将数据集划分为训练集(80%)、测试集(10%)和验证集(10%)。同时为了避免模型结果的随机性，提高实验结果的可信性和有效性，对训练集采用五折交叉验证。

3.2 实验结果

3.2.1 实验参数

在传统 CNN 的基础上对网络结构进行改进，对于 CNN 训练过程，采用 5 折交叉验证方法来调节网络参数，同时使用了 early stop 策略，监测值为验证集 loss 值，采用小批量数据集 ( Batch size=64 ) 进行训练更新，对于分类器的选择上针对不同的实验选用不同的分类器，但是总体来说训练、验证和测试过程中一共采用五种分类器，分别是支持向量机、K 最近邻、随

机森林、逻辑回归和梯度提升树。训练结束后，取验证集训练最好的权重作为后续预测的权重。在建立好 CNN 模型之后，结合不同的分类器进行分类。关于卷积神经网络的相关参数设置见表 2。

表 2 相关参数设置

参数名称	参数设置
迭代次数	1000
激活函数	LReLU
分类器	SVM、KNN、RF、LR、GBDT
Batch size	64
损失函数	交叉熵+L2 正则化
全连接层	两层
池化	最大池化
Dropout	0.5 (train)、1 (test、validation)
优化器	Adam

3.2.2 分类器对比分析

本实验为三分类问题，为了检验本研究方法在基于脑电信号的情感识别中的有效性，实验中选用了 4 种其他分类方法进行对比，见表 3。

表 3 对比分类器名称

分类器名称	简写
K 最近邻	KNN
逻辑回归	LR
支持向量机	SVM
梯度提升树	GBDT

分类器对比实验选则被试 10、被试 11、被试 12、被试 13、被试 14、被试 15 进行实验。表 3 对比了本研究方法与其它 4 种方法的准确率和分类器训练总时间。从图 5 训练时间的角度来看，随机森林分类器的训练时间最短，支持向量机因其特征映射到高维空间而导致训练的时间最长；从准确率的角度来看，忽略训练时间，采用随机森林方法仍然具有一定的优势。

图 4 展示了这五种方法准确率的对比结果，被试 12、被试 13、被试 14、被试 15 体现了随机森林算法的优势性，由于被试的个体差异和分类器的随机性，不可避免的导致被试 10 的随机森林分类器性能稍逊色 SVM 和 GBDT 分类器；权衡准确率与分类器训练时间，综合考虑实际需求，随机森林算法由于能够在 2 分钟以内达到 92.35% 以上的正确率。从实验结果可知，本研究 RF 模型呈现出明显的优势，平均准确率达到了 94.7%，说明随机森林分类器模型在关于脑电

信号的情感识别研究上具有很好的分类性能。




图 4 五种方法的准确率直方图




图 5 五种方法的训练时间直方图

表 4 对比分类器结果

	KNN		LR		RF		SVM		GBDT	
	Time(s)	Accuracy	Time(s)	Accuracy	Time(s)	Accuracy	Time(s)	Accuracy	Time(s)	Accuracy
Subject10	18.91	94.12%	2.60	95.88%	1.02	96.28%	2600.89	96.47%	300.45	96.47%
Subject11	15.50	94.71%	4.31	93.53%	0.89	96.89%	2905.64	94.12%	318.88	95.29%
Subject12	15.84	90.59%	2.69	91.76%	1.12	93.35%	2755.76	90.59%	311.45	92.35%
Subject13	15.09	90.59%	6.92	93.53%	0.92	94.53%	3106.93	92.94%	315.97	93.53%
Subject14	5.98	92.94%	17.64	92.94%	1.18	93.53%	1433.67	92.94%	380.05	92.94%
Subject15	18.72	97.06%	12.69	97.06%	1.78	98.24%	3089.39	97.65%	340.05	97.65%

3.2.3 随机森林分类器性能分析

上述分类器对比实验已经证明了随机森林分类器的优越性，为了更加全面的评价分类器的性能，本研究采用了另外三个模型评价指标，即精确率、召回率和  $F1-Measure$ 。精确率与召回率一般呈负相关关系，从表 5 可知，不同被试的精准率和召回率之间约相差 0.02，且整体保持在 0.83 以上，虽然不同被试之间存

在个体差异性，但是整体在 0.83~0.95 之间，说明模型具有很好的泛化能力。对于综合评价指标  $F1-Measure$  而言，不同被试的值均在 0.84 以上，表明在精确率与召回率同等重要的情况下，本文方法取得了较为理想的结果，随机森林分类器模型具有很高的性能。

表 5 随机森林分类器结果

	Subject1	Subject2	Subject3	Subject4	Subject5	Subject6	Subject7	Subject8	Subject9
Precision	0.8922	0.8370	0.8967	0.9519	0.9171	0.9599	0.9407	0.9407	0.9475
Recall	0.9000	0.8412	0.9000	0.9529	0.9235	0.9647	0.8287	0.9471	0.9475
F1-Measure	0.9003	0.8402	0.9001	0.9533	0.9240	0.9652	0.8357	0.9465	0.9765

3.2.4 同类研究对比

为了进一步验证本文 CNN 自动特征提取的科学性和优越性，将与同样采用 SEED 数据集的传统特征提取方法进行对比分析。文献 [20] 以微分熵 (Differential Entropy, DE) 为脑电信号的情感特征，结合深度信念网络 (Deep Belief Network, DBN) 进行通道选择，最终得到 86.65% 的分类精度；文献 [21] 提取了功

率谱 (Power spectrum)、小波 (Wavelet) 和非线性动力学 (Nonlinear dynamical) 特征以评估脑电数据和情绪状态之间的关联，通过线性动态系统 (Linear dynamical system, LDS) 平滑法消除特征的无关噪声，利用线性判别分析 (Linear discriminant analysis, LDA) 特征降维，最终通过 SVM 获得最佳平均分类精度 91.77%；文献 [22] 将一维脑电时域信息转换成二维的微分熵频域特征，



结合分层卷积神经网络(Hierarchical Convolutional Neural Networks, HCNN)做二次特征提取，获得了88.20%的识别精度，由表6可知，本文的CNN-RF方法在SEED数据集上取得了很明显的优势。

表6 同类研究对比

Method	Accuracy(%)
Zheng et al. [20]	86.65
Wang et al. [21]	91.77
Li et al. [22]	88.20
This article	94.70

## 4 总结与展望

关于深度学习的研究已经成为当今人工智能领域的热门方向，越来越多的科研人员将目光锁定在深度学习的应用上。本文使用了一个8层改进的卷积神经网络来提取脑电信号的情感特征，有效避免了传统方法数据重建过程，同时使用随机森林模型作为分类器，最终达到94.7%的正确率，表明所使用方法的可行性，这使得卷积神经网络在情感识别方面具有较好的研究潜力和应用前景。通过实验发现，提出的一维卷积神经网络的参数和结构仍然具有提升的空间，可以做进一步讨论和研究，所以在未来的工作中，将深入研究网络结构和参数，提高识别率。

## 参考文献：

- [1] Bhardwaj A, Gupta A, Jain P, et al. Classification of human emotions from EEG signals using SVM and LDA Classifiers[C]//International Conference on Signal Processing and Integrated Networks. IEEE, 2015: 180-185.
- [2] Yazdani A, Lee J S, Ebrahimi T. Implicit emotional tagging of multimedia using EEG signals and brain computer interface[C]//ACM, 2009:81-88.
- [3] Murugappan M, Ramachandran N, Sazali Y. Classification of human emotion from EEG using discrete wavelet transform [J]. Engineering, 2010, 03 (4):390-396.
- [4] LeCun Y, Boser B, Denker J S, et al. Back propagation applied to hand written zip code recognition[J]. Neural Computation, 1989, 1(4): 541-551.
- [5] Krizhevsky A, Sutskever I, Hinton G. ImageNet classification with deep convolutional neural networks[C]//Proc. of the Advances in Neural Information Processing Systems. New York, NY, ACM, 2012: 1097-1105.
- [6] 周志华. 机器学习: Machine learning[M]. 清华大学出版社, 2016.
- [7] Theodoridis S. Neural Networks and Deep Learning[M]//Machine Learning. 2015.
- [8] 周飞燕, 金林鹏, 董军. 卷积神经网络研究综述[J]. 计算机学报, 2017, 40(6):1229-1251.
- [9] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]// International Conference on Neural Information Processing Systems. Curran Associates Inc. 2012:1097-1105.
- [10] Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C].International Conference on Machine Learning. 2015:448-456.
- [11] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting [J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [12] Lecun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553):436.
- [13] He K, Zhang X, Ren S, et al. Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification[J]. IEEE Computer Society, 2015: 1026-1034.
- [14] Breiman L. Random Forests[J]. Machine Learning, 2001, 45(1):5-32.
- [15] Breiman L. Bagging Predictors[J]. Machine Learning, 1996, 24(2):123-140.
- [16] Li C, Tang Y, Li C. A GERT-based analytical method for remanufacturing process routing[C]//IEEE International Conference on Automation Science and Engineering. IEEE Computer Society, 2011:462-467.
- [17] Zhang M, Xu H, Wang X, et al. Application of Google TensorFlow machine learning framework[J]. Microcomputer & Its Applications, 2017.
- [18] Zheng W L, Zhu J Y, Peng Y, et al. EEG-based emotion classification using deep belief networks[C]//IEEE International Conference on Multimedia and Expo. IEEE Computer Society, 2014:1-6.
- [19] Pfurtscheller G, Vaughan A T M, Wolpaw J R, et al. Brain-computer interfaces for communication and control[J]. Supplements to Clinical Neurophysiology, 2002, 57(5):607.
- [20] Zheng W L, Guo H T, Lu B L. Revealing critical channels and frequency bands for emotion recognition from EEG with deep belief network[C]//International IEEE/EMBS Conference on Neural Engineering. IEEE, 2015: 154-157.
- [21] Wang X W, Nie D, Lu B L. Emotional state classification from EEG data using machine learning approach[J]. Neurocomputing, 2014, 129(4):94-106.
- [22] Li J, Zhang Z, He H. Implementation of EEG Emotion Recognition System Based on Hierarchical Convolutional Neural Networks[J]. Lecture Notes in Computer Science book series, 2016.