



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: 融合多维度卷积神经网络的肺结节分类方法
作者: 吴保荣, 强彦, 王三虎, 唐笑先, 刘希靖
网络首发日期: 2018-12-20
引用格式: 吴保荣, 强彦, 王三虎, 唐笑先, 刘希靖. 融合多维度卷积神经网络的肺结节分类方法[J/OL]. 计算机工程与应用.
<http://kns.cnki.net/kcms/detail/11.2127.tp.20181217.1735.016.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

融合多维度卷积神经网络的肺结节分类方法

吴保荣¹, 强彦¹, 王三虎², 唐笑先³, 刘希靖⁴

WU Baorong¹, QIANG Yan¹, WANG Sanhu², TANG Xiaoxian³, LIU Xijing⁴

1. 太原理工大学 信息与计算机学院, 山西 晋中 030600

2. 吕梁学院 计算机科学与技术系, 山西 吕梁 033000

3. 山西省人民医院 PET/CT 中心, 太原 030024

4. 山西农业大学 软件学院, 山西 晋中 030600

1. College of Information and Computer, Taiyuan University of Technology, Jinzhong, Shanxi 030600, China

2. College of Computer Science and Technology, Lüliang University, Lüliang, Shanxi 033000, China

3. Department of PET/CT center, Shanxi Provincial People's Hospital, Taiyuan 030024, China

4. College of Software College, Shanxi Agricultural University, Jinzhong, Shanxi 030600, China

WU Baorong, QIANG Yan, WANG Sanhu, et al. Fusing multi-dimensional convolution neural network for lung nodules classification. Computer Engineering and Applications

Abstract: In order to solve the problem of low classification precision and high false positive in the classification task of lung nodules in CT image, a benign and malignant classification model of lung nodules based on weighted fusion multi-dimensional convolution neural network was proposed. The model contained two sub-models: a multi-scale dense convolutional network model based on two-dimensional images to capture more extensive nodule variation features and promote feature reuse, and the three-dimensional convolutional neural network model based on three-dimensional images to make full use of spatial context information of nodules. Firstly, 2D and 3D CT images were used to train the sub-models. Secondly, the weights of the sub-models are calculated according to the classification errors, and then the weights were used to fuse the sub-models classification results. Finally, the more accurate classification results were obtained. The classification accuracy of the model was 94.25% and the AUC value was 98% on the public dataset LIDC-IDRI. The experimental results show that the weighted fusion multi-dimensional model can effectively improve the classification performance of lung nodules.

Key words: lung nodule classification; convolutional neural network; deep learning; multi-dimensional; weighted fusion; CT image

基金项目：国家自然科学基金 (No.61572344)；虚拟现实技术与系统国家重点实验室开放基金 (No.BUAA-VR-17KF-14)；虚拟现实技术与系统国家重点实验室开放基金(No.VRLAB2018A07)；山西省回国留学人员科研资助项目(No.2016-038)。

作者简介：吴保荣(1994—),女,硕士研究生,研究领域为医学图像处理、深度学习,E-mail:2395837943@qq.com;强彦(1969—),男,教授,博士,CCF 会员,研究领域为医学图像处理、模式识别、云计算;王三虎(1969—),男,教授,硕士,研究领域为医学图像处理与算法分析;唐笑先(1963—),女,主任医师,硕士,研究领域为肺部、心血管、腹部图像的 CT 诊断;刘希靖(1997—)女,本科,研究领域为软件工程。

摘要: 针对 CT 图像肺结节分类任务中分类精度低, 假阳性高的问题, 提出了一种加权融合多维度卷积神经网络的肺结节分类模型, 该模型包含两个子模型: 基于二维图像的多尺度密集卷积神经网络模型, 以捕获更宽泛的结节变化特征并促进特征重用; 基于三维图像的三维卷积神经网络模型, 以充分利用结节空间上下文信息。首先使用二维和三维 CT 图像训练子模型, 之后根据子模型分类误差计算其权重, 再对子模型分类结果进行加权融合, 得到最终分类结果。该模型在公共数据集 LIDC-IDRI 上分类准确率达到 94.25%, AUC 值达到 98%。实验结果表明, 加权融合多维度模型可以有效的提升肺结节分类性能。

关键词: 肺结节分类; 卷积神经网络; 深度学习; 多维度; 加权融合; CT 图像

文献标志码: A **中图分类号:** TP391.41 **doi:** 10.3778/j.issn.1002-8331.1809-0190

1 引言

肺癌是导致癌症相关死亡的主要原因, 其 5 年生存率仅为 18%^[1], 肺癌的早期诊断和治疗是降低死亡率的重要手段, 肺结节作为肺癌的早期表现形式^[2], 其良恶性诊断对于放射科医生进行结节分期评估和个体化治疗计划是非常重要的。随着医学成像技术的发展, 肺部 CT 图像数量不断增加, 但有经验的医师数量有限, 导致影像数据爆炸式增长与人工诊断力量严重不足的问题。因此, 迫切需要计算机辅助诊断技术来为医师提供客观的决策支持, 辅助医师诊断。

然而, 大多数传统的肺结节分类方法并不是以端到端的方式工作: 首先使用预定义的滤波器提取特征或者提取手工构造的特征, 然后再训练分类器对结节进行分类。Way 等人^[3]首先对结节进行分割, 然后提取纹理特征来训练线性判别分类器。Han 等人^[4]首先比较三种 2D 纹理特征的分类性能, 再将 2D 纹理特征扩展到三维空间, 使用支持向量机进行分类。对于日益增长的 CT 图像, 手工提取特征过程复杂且耗时长。最近提出的卷积神经网络(Convolutional Neural Network, CNN)已经成为学习判别性特征的强大工具来适应不同视觉任务^{[5][6]}。得益于层级网络结构的强大特征学习能力, CNN 模型在医学图像分析任务中取得了优秀的成果^[7,8,9], 表明其对医学图像分析的有效性。在肺结节分类方面, Kumar D 等人^[10]使用自编码方法进行肺结节分

类, 该方法属于无监督学习方法, 没有先验标记信息。Shen 等人^[11]提出的多裁剪卷积神经网络(Multi-Crop Convolutional Neural Network, MC-CNN), 为了简化训练过程, 将多个 CNN 替换为专门针对肺结节恶性度分类的多裁剪池化结构。Zhu 等人^[12]对于结节分类, 提出了一种具有三维双路径网络特征的梯度增强机。Kang 等人^[13]提出三维多视点卷积神经网络(Multi-View Convolutional Neural Network, MV-CNN)对肺结节进行分类, 得到优秀的分类性能, 表明三维卷积神经网络的有效性。此外, 一些研究者提出特征级或决策级融合方法用于肺结节分类, Wang 等人^[14]提出融合手工提取特征和深度学习特征, 再使用代价敏感随机森林(Cost-Sensitive Random Forest, CS-RF)进行分类。Xie 等人^[15]提出了一种在决策层融合纹理、形状和深度模型学习信息(Fuse-TSD)的肺结节分类算法。

鉴于深度学习方法在医学图像分析的有效性以及融合策略对分类性能的提升, 本文提出一种基于加权融合多维度卷积神经网络的肺结节良恶性分类模型(Fusion-MDCNN)。在二维 CT 图像上, 出于结节大小差异显著的临床事实, 在 DenseNet^[6]中引入多尺度策略, 提出多尺度密集卷积神经网络(Multi-Scale Dense Convolutional Network, MS-DenseNet), 在不涉及多个网络的情况下学习多尺度特征, DenseNet 可以缓解梯度消失问题, 促进特征重用; 由于 CT 序列图像三维性质, 使用三维卷积神经网络模型(3D Convolutional Neural Net-

work, 3D CNN)学习三维 CT 图像空间上下文信息；为了进一步提高肺结节分类的准确性，在各个维度的模型训练结束后，将其分类结果进行自适应加权融合，最终得到更加准确的分类结果。

2 方法

提出的融合模型 Fusion-MDCNN 如图 1 所示，该模型包括三部分，第一部分(如图 1(a)所示)是 MS-DenseNet 分类模型，在同一个网络模型中学习

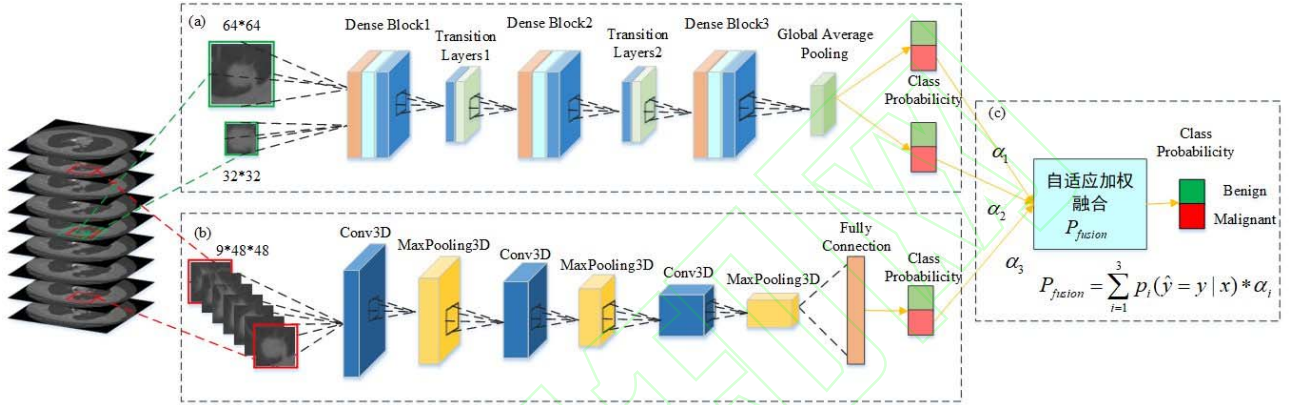


图 1 Fusion-MDCNN 模型框架图

2.1 多尺度二维肺结节分类模型

由于肺结节大小差异显著，结节直径范围从小于 3mm 到 30mm 以上不等^[16]，本文在 DenseNet 中加入多尺度策略，提出 MS-DenseNet 模型，该模型通过共享网络结构同时学习两个尺度的结节块，捕获结节变化信息。DenseNet 与一般卷积神经网络不同之处是，它的任意一层不仅与相邻层有连接，而且与它随后的所有层都有直接连接，这种直接连接方式有效缓解了梯度消失问题，还增强特征传递，促进特征重用。

2.1.1 MS-DenseNet 网络结构

MS-DenseNet 模型通过共享网络结构学习多尺度特征，而不是为每个尺度的结节图像训练独立的网络模型，并且该模型对不同尺度的输入有对应的输出分支，以达到在不同尺度判别结节良恶性。MS-DenseNet 模型的详细结构如图 1(a)所示，该模型包含 3 个 Dense Block(密集块)、2 个 Transition

结节多尺度特征，并通过对特征的充分利用，在使用更少参数的同时达到更好的效果，第二部分(如图 1(b)所示)是三维卷积神经网络分类模型 3D CNN，该模型能够充分利用三维 CT 图像空间上下文信息，提取出更具判别性的特征，第三部分(如图 1(c)所示)是将模型分类结果进行加权融合，以达到更准确的分类结果。

layer(过渡层)和 1 个全局平均池化层，最后以 Softmax 层结束，以获得最终分类概率。

每个密集块中每一层和所有后续层直接连接。因此，第 l 层接收前面所有层的特征图作为输入， $x_l = H_l([x_1, x_2, \dots, x_{l-1}])$ ， $[x_1, x_2, \dots, x_{l-1}]$ 指前 $l-1$ 层特征图的合并， H_l 表示作用在上面的复合操作：BN-ReLU-Conv(1*1)-BN-ReLU-Conv(3*3)，每个 3*3 卷积前面都包含一个 1*1 卷积操作，目的是减少输入的特征图数量，使用 ReLU (Rectified Linear Unit) 激活函数^[17]，以及 BN(Batch Normalization^[18])操作进行归一化。在每个密集块之间加入过渡层，过渡层由 BN 层、1*1 卷积层、2*2 平均池化层组成，因为每个密集块之后输出通道个数很多，需要用 1*1 的卷积来进行降维。最后使用全局均值池化取每个特征图的平均值，并将得到的矢量直接输入 Softmax 层计算分类结果，采用全局均值池化可以大大减小网络参数，避免过拟合。

2.1.2 MS-DenseNet 多输出损失函数设计

在训练时，给出训练样本集合 $S=\{(X_i, Y_i)\}$ ($i=1,2,\dots,N$)，学习 MS-DenseNet 的参数 W ， X_i 是训练图像块， Y_i 是类别标签， $Y_i = y_i \in \{0,1\}$ ，0 表示良性结节，1 表示恶性结节。损失函数定义为：

$$L(W) = \sum_{m=1}^M \sum_{i \in S^m} \alpha_m l^m(X_i, Y_i | W) \quad (1)$$

公式(1)中 M 是输出分支的个数($M=2$)， S^m 表示尺度 m 的样本， α_m 是损失 l^m 的权重，训练样本 S^m 只对尺度为 m 的损失有贡献。每个尺度分类分支的损失计算如下：

$$l(X, Y | W) = L_{cls}(p(X), y) \quad (2)$$

$$p_i(X) = \exp(o_i) / \sum_{i=0}^1 \exp(o_i) \quad (3)$$

公式(2)中， $p(X)=(p_0(X), p_1(X))$ 是每个类别的概率值，计算公式如公式(3)所示， $L_{cls}(p(X), y) = -\text{lb } p_y(X)$ (此处公式中 \log 已修改为 lb) 是交叉熵损失。

2.2 三维肺结节分类模型

肺结节在体积、形状及许多其他特征如精细度、内部结构、球形度等方面有很大的变化^[16]，并且往往具有复杂的上下文环境。手工提取特征识别能力不足以在复杂环境中判别肺结节的良恶性，并且二维卷积忽略连续切片间结节变化信息，不能充分利用三维空间上下文信息。然而，3D CNN 可以充分考虑到结节空间上下文信息，弥补这些问题。为了有效地将连续切片中结节的变化信息提取出来，利用 3D CNN 强大的识别能力，在 CNN 的卷积层中执行 3D 卷积，从而捕获空间维度的判别性特征。

2.2.1 3D CNN 网络结构

一般来说，3D CNN 由 3D 卷积层，3D 最大池化层和全连接层组成。每层包含多个通道，编码不同的特征表示。对于 3D CNN，卷积层/最大池化层中的每个通道实际上是三维特征体，而不是传统 2D CNN 中的二维特征图。本文提出的 3D CNN 模型详细结构如图 1(b)所示，包含三个 3D 卷积层，三个

3D 最大池化层，以及输出特征的全连接层，最后是 Softmax 层输出分类结果。从输入 3D 结节块到最终特征层，特征体的大小不断减少，有助于去除原始结节中潜在的冗余信息，获得结节分类的判别性特征。

3D 卷积层：网络从 3D 卷积层开始，为了构建 3D 卷积层，首先建立一系列较小的 3D 卷积核来提取更高层次的特征表示，不同特征表示对应不同的 3D 卷积核。形式上，输入和卷积核之间的卷积操作定义为：

$$h_i^l(x, y, z) = \sigma(b_i^l + \sum_k \sum_{p,q,r} h_k^{l-1}(x+p, y+q, z+r) * W_{ki}^l(p, q, r)) \quad (4)$$

公式(4)中 h_i^l 和 h_k^{l-1} 分别表示第 l 层第 i 个特征和第 $l-1$ 层第 k 个特征， W_{ki}^l 是第 l 层的 3D 卷积核， $h_i^l(x, y, z)$ ， $h_k^{l-1}(x+p, y+q, z+r)$ (此公式已修改) 和 $W_{ki}^l(p, q, r)$ 分别表示对应坐标位置的体素值， b_i^l 是偏置项， $\sigma(*)$ 表示非线性激活函数，使用 ReLU。在添加偏差项之前，对不同 3D 卷积核的激活求和，公式(4)中 k 表示来自不同 3D 卷积核的累加数目。为了加快训练过程，每个卷积层后面都会跟着 BN 操作来归一化输出。

3D 最大池化层：紧接着 3D 卷积层的是 3D 最大池化层，用来对特征进行子采样，并获取 3D 空间中局部平移的不变性。假定第 l 层是 3D 卷积层，第 $(l+1)$ 层是 3D 最大池化层，则最大池化层接受 4D 张量 $T = [h_1^l, h_2^l, \dots, h_k^l] \in R^{X \times Y \times Z \times K}$ 。对于 3D 最大池化操作，它选择一个立方邻域内的最大值激活，并生成一个抽象输出 $T' \in R^{X' \times Y' \times Z' \times K}$ ，其中 (X, Y, Z) 和 (X', Y', Z') 分别是 3D 最大池化操作前后的特征体大小， K 表示在池化操作过程中特征体数量保持不变。

全连接层每个神经元与相邻层中的所有神经元连接，首先把 3D 特征体拉平成神经元向量，执行向量-矩阵乘法，然后添加偏置，使用 ReLU 生成激活，在全连接层使用 dropout^[19]策略提高模型泛化能力，最后输入到 Softmax 层计算每类的预测概率。

2.2.2 3D CNN 损失函数

在训练 3D CNN 时，给出训练样本集合 $S^{3D} = \{(X_i^{3D}, Y_i)\} (i=1, 2, \dots, N)$ ， X_i^{3D} 是输入的 3D 结节块， Y_i 是对应的标签， $Y_i = y_i \in \{0, 1\}$ ，0 表示良性结节，1 表示恶性结节，3D CNN 所有可训练参数用 W^{3D} 表示，构造以下损失函数：

$$L(W^{3D}) = \frac{1}{N} \sum_{i=1}^N L_{cls}(p(X_i^{3D}), y) \quad (5)$$

公式 (5) 中的 N 表示样本总数目， $L_{cls}(p(X_i^{3D}), y) = -\log p_y(X_i^{3D})$ (此处公式中 \log 已修改为 \ln) 表示交叉熵损失， $p_y(X_i^{3D})$ 即是 Softmax 层计算得到的样本 X_i^{3D} 属于类别 y 的估计概率值。

2.3 多模型加权融合策略

上述提出的任意一个模型都可作为单独的分类器，其预测结果可以作为最终分类结果。研究表明，多分类器的组合、分类器集成，能够实现比单分类器模型^[15,20]更好的性能，该方法也被用于传统神经网络组合，因此，本文提出使用多模型加权融合方法，进一步提升分类性能。本文将训练得到 MS-DenseNet 模型和 3D CNN 模型作为基本分类器，根据其分类误差计算权重，再将模型分类结果根据权重，按照加权方式进行融合，充分考虑到各个分类模型的特点。MS-DenseNet 模型可以捕获更宽泛的结节异质性信息，3D CNN 模型通可以对更丰富的空间信息进行编码，最终得到更优秀的分类结果。

$$\alpha_i = \frac{1}{2} \ln\left(\frac{1-e_i}{e_i}\right) \quad (6)$$

$$P_{fusion} = \sum_{i=1}^3 p_i(y_i = y | x_i) \alpha_i \quad (7)$$

公式 (6) 为各个模型权重计算公式，其中 e_i 是各个模型的分类误差，当 $e_i \leq 1/2$ 时， $\alpha_i \geq 0$ ，且 α_i 随着 e_i 的减小而增大。提高分类误差小的模型权重，使其在最终的分类中起着较大的决定作用，同时降低分类误差大的模型权重，使其在最终的分类中起着较小的决定作用。

公式 (7) 是模型加权融合后的结果，其中

$p_i(y_i = y | x_i)$ 是各个模型分类结果， α_i 是公式 (6) 中计算得到的权重。

$$y' = \begin{cases} 1, & P_{fusion}[1] > P_{fusion}[0] \\ 0, & else \end{cases} \quad (8)$$

公式 (8) 中 y' 是最终预测标签，如果 $P_{fusion}[1] > P_{fusion}[0]$ ， $y'=1$ 为恶性结节， $y'=0$ 为良性结节。

3 数据集和实验设置

3.1 数据集

在 LIDC-IDRI 数据集^[16]上进行评估，该数据集由国家癌症研究所收集，现在总共包含 1018 个病例，每个病例包含临床胸部 CT 扫描图像和相关的 xml 文件，记录了 4 名有经验的胸部放射科医生的标注，包括结节位置、边缘、纹理等信息。本文在 LIDC-IDRC 数据集的基础上去除了切片厚度 $> 3\text{mm}$ 的病例，以及切片间距不一致的病例，最终得到 888 病例。根据 LIDC-IDRI 数据集的结节报告，得到 4 名放射科医师对结节恶性程度评分 (1-5 级，1 代表低恶性，5 代表高恶性)，选择每个结节的平均恶性程度评分。对于平均分低于 3 分的结节，将其标记为良性结节；对于平均分数高于 3 的结节，将其标记为恶性结节。移除平均得分为 3 的结节 (不确定恶性或良性)。最终得到 1186 个结节，有 650 个良性结节和 536 个恶性结节，其中 75% 用于训练集和验证集，15% 用于测试集。

3.2 实验细节

本文实验的硬件环境是基于 HPDL580G7 服务器，32GB 内存；软件环境是基于 Ubuntu16.04 系统的 Keras 深度学习框架 (Keras 2.0.6 版本)，使用语言为 Python (Python3.6 版本)。

实验中采用小批量梯度下降 (Mini-batch Gradient Descent, MBGD) 方法学习每个分类模型的权值 W ，最小化损失函数。以候选位置为中心提取出 $32 \times 32, 64 \times 64$ 和 $48 \times 48 \times 9$ 的图像块，分别输入到对应的分类模型中。为了解决数据样本量不足问题，对训练集样本进行平移、旋转操作进行数据增强。

具体来说,将质心坐标在每个轴上正负平移两个像素,二维训练样本增加4倍,三维训练样本则增加6倍,而且有助于获得平移不变性特征;并在横向平面内旋转90、180和270度,进一步提升训练样本数量。在训练过程中,使用高斯分布随机初始化权值,标准反向传播更新,学习速率初始化为0.1,每2000次迭代衰减5%,将批量大小设为64,动量设为0.9。使用5折交叉验证策略来评估该方法的性能,在训练和测试数据集中保持相似的数据分布,以避免由于数据集中的不平衡而导致每类的过度表示和不足表示。

3.3 评估标准

根据给定的标签和预测结果,使用准确率,敏感性和特异性用作主要的评估标准来评估提出模型的性能。

准确率: $\text{Accuracy(ACC)} = (\text{TP} + \text{TN}) / (\text{TP} + \text{FN} + \text{FP} + \text{TN})$

敏感性: $\text{Sensitivity(SEN)} = \text{TP} / (\text{TP} + \text{FN})$

特异性: $\text{Specificity(SPE)} = \text{TN} / (\text{FP} + \text{TN})$

其中: TP (True Positive): 实际标签为正样本,预测标签为正样本的样本数量, FN(False Negative): 实际标签为正样本,预测标签为负样本的样本数量, FP (False Positive): 实际标签为负样本,预测标签为正样本的样本数量, TN (True Negative): 实际标签为负样本,预测标签为负样本的样本数量。

4 结果和分析

4.1 单独模型分类性能

将各个分类模型作为单独分类器,评估其分类性能,如表1所示。MS-DenseNet(32*32, 64*64)和3D CNN 分类模型总体准确率分别达到85.37%, 89.62%和91.07%。通过对单独分类模型的比较,可以看出3D CNN 比MS-DenseNet 的效果要好,这是由于3D CNN 可以更好利用结节空间上下文信息,提取出更具判别性特征,同时也证明3D 卷积层的优势。在MS-DenseNet 中,输入尺度为64*64大小的模型其分类性能比输入尺度为32*32的要更好一

些,这是因为64*64大小图像块包含的结节信息更多,更有助于结节分类。使用一般2DCNN(3个卷积层,3个最大池化层,2个全连接层,1个Softmax层)进行肺结节分类,在同等尺度图像下,提出的MS-DenseNet 和一般2DCNN 相比,MS-DenseNet 的性能明显较高,同样,3DCNN 的分类性能大大优于2DCNN。由此表明,本文提出的子模型可以作为单独的分类器用于肺结节分类。

表1 不同模型分类性能比较

Model	ACC(%)	SEN(%)	SPE(%)
2DCNN(32*32)	80.36	78.92	81.43
2D CNN(48*48)	83.82	81.43	84.60
2D CNN(64*64)	84.86	82.59	86.67
MS-DenseNet(32*32)	85.37	83.21	86.87
MS-DenseNet(64*64)	89.62	87.39	90.82
3D CNN(48*48)	91.07	88.74	92.57
Fusion-MDCNN	94.25	90.18	94.42

4.2 加权融合模型分类性能

融合模型 Fusion-MDCNN 分类性能评估结果如表1所示, Fusion-MDCNN 的总体准确率达到94.25%,各方面性能明显高于任意一个单独分类模型,该实验结果表明,多模型融合方法对于提高分类性能是有效的。同时使用受试者工作特征 (Receiver Operating Characteristic, ROC) 曲线来评估分类模型的性能,对不同的 ROC 曲线进行比较的一个指标是曲线下面积 (Area Under Curve, AUC), AUC 是分类模型的平均性能值, AUC 越大,模型的性能越好。如图2所示是各个分类模型 MS-DenseNet (32*32, 64*64), 3DCNN 和加权融合模型 Fusion-MDCNN 的 ROC 曲线及 AUC 值,加权融合模型 Fusion-MDCNN 的曲线明显高于单独分类模型,并且 AUC 值最大(AUC=0.98),其分类性能相比3D CNN 和MS-DenseNet 具有很强的竞争力,同样表明模型融合的对性能提升的重要性。

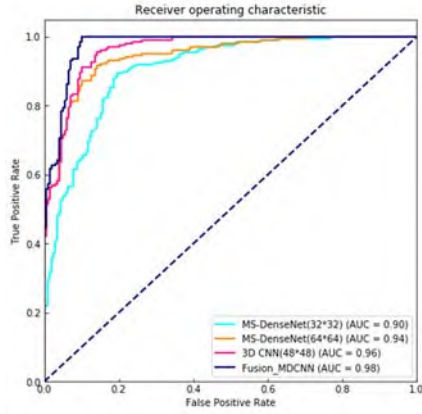



图 2 分类模型 ROC 曲线

4.3 融合分类模型验证及结果可视化

将本文融合分类模型 Fusion-MDCNN 在测试集结节图像上进行验证，并对测试集部分分类结果进行可视化。如图 3 所示，图 3(a)是融合分类模型对待分类的测试图像进行分类的过程，输入测试结节图像，融合模型 Fusion-MDCNN 输出最终分类结果，其中绿色块和数字是预测为良性结节的概率，红色块和数字是预测为恶性的概率，如果恶性概率大于 0.5，则是恶性结节，否则是良性结节。图 3 (b) 是测试集部分结节分类结果展示，前三行是 Fusion-MDCNN 预测正确的结节，其中，第一二行是预测正确的恶性结节，第三行是预测正确的良性结节。对于大部分结节，融合分类模型能够以 90% 以上的概率确定其良恶性，特别地，对于小部分特征明显的结节，融合模型能够 100% 确定其良恶性，可见融合分类模型具有优秀的分类性能。第四行是 Fusion-MDCNN 预测错误的结节，其中，前三列是错误把恶性结节预测为良性结节，后三列是错误把良性结节预测为恶性结节。比如左下角结节，由于模型不能找到一些弱的不规则边界，导致最终预测它们是良性结节。Fusion-MDCNN 是对各个维度子模型的加权融合，如图 4 所示是从各个子模型卷积层中随机选择的特征图。

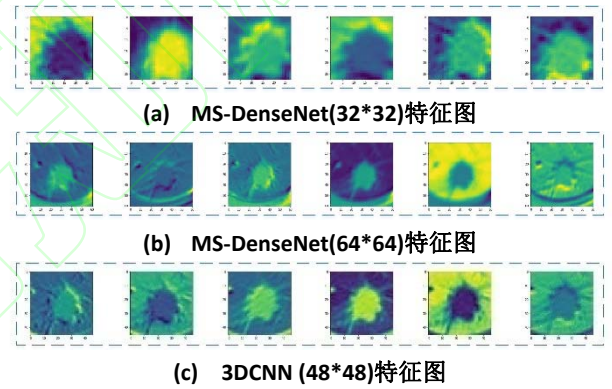


(a) 融合分类模型 Fusion-MDCNN 结节分类流程图



(b) 部分分类结果可视化

图 3 融合分类模型 Fusion-MDCNN 测试集分类结果



(c) 3DCNN (48*48)特征图

图 4 特征图可视化

4.4 与其他分类方法的比较

本文方法和其他在 LIDC-IDRI 数据集上分类方法的性能评估如表 2 所示。Han 等人^[4]提出的算法只使用纹理特征来区分结节外观，获得了较低的准确率。Dhara 等人^[21]对形状、边缘锐度和基于灰度共生矩阵的纹理特征进行了广泛的挖掘，具有较高的精度。Xie 等人^[15]出的算法得到较高的准确率，可能是使用多种类型特征进行决策级融合的原因，其中包含深度学习特征、纹理特征以及形状特征。Kumar 等人^[10]提出基于自动编码器的无监督学习，无监督学习中缺乏先验标签信息可能导致学习能力的次优，导致其分类精度低于其他方法。从表 2

中可以看出其他方法的准确率和 AUC 均低于提出的 Fusion-MDCNN 模型。可见提出使用多模型加权融合方法可以有效提升肺结节分类性能。

表 2 与其他方法结节分类性能比较

方法	AUC(%)	ACC(%)	SEN(%)	SPE(%)
Han et al.[4]	89.25	85.59	70.62	93.02
Dhara et al. [21]	95.76	88.38	84.58	90.03
Kumar et al [10]	86.00	80.29	73.00	85.00
Shen et al. [11]	93.00	87.14	77.00	93.00
Xie et al.[15]	96.65	89.53	84.19	92.02
Fusion-MDCNN	98.00	94.25	90.18	94.42

5 结束语

本文针对肺结节良恶性分类问题提出了基于多模型加权融合的肺结节分类模型，该模型可以同时提取多尺度二维和三维敏感特征。首先训练 MS-DenseNet 和 3D CNN 子模型，之后通过加权方法融合模型分类结果，进一步提高分类的准确性。MS-DenseNet 通过多尺度结节图像学习结节变化特征，多尺度策略保证模型能够在不涉及多个网络的情况下学习多尺度特征，3D CNN 能够编码更丰富的空间信息，学习结节空间上下文信息，提取出判别性特征。该模型不需要结节分割和手工提取特征等操作，可以简化常规的肺结节良恶性分类，同时可以达到很好的分类性能。在 LIDC-IDRI 数据集上的分类结果验证该模型的有效性，可以给医师提高客观的辅助诊断。下一步研究工作将根据三维卷积神经网络的空间信息学习能力，通过实验进一步优化网络结构，提高肺结节分类性能，为医师提供更可靠的决策支持，未来会将这些方法应用到肺部不同肿瘤类型分类上，并根据具体问题进一步优化方法。

参考文献:

- [1] Siegel R L, Miller K D, Jemal A. Cancer statistics, 2016[J]. CA: a cancer journal for clinicians, 2016, 66(1): 7-30.
- [2] Jacobs C, van Rikxoort E M, Scholten E T, et al. Solid, part-solid, or non-solid?: classification of pulmonary nodules in low-dose chest computed tomography by a computer-aided diagnosis system.[J]. Investigative Radiology, 2015, 50(3):168-73.
- [3] Way T W, Hadjiiski L M, Sahiner B, et al. Computer-aided diagnosis of pulmonary nodules on CT scans: segmentation and classification using 3D active contours [J]. Medical Physics, 2006, 33(7):2323-2337.
- [4] Han F, Wang H, Zhang G, et al. Texture feature analysis for computer-aided diagnosis on pulmonary nodules [J]. Journal of digital imaging, 2015, 28(1): 99-115.
- [5] Girshick R. Fast R-CNN[C]// IEEE International Conference on Computer Vision. IEEE, 2015:1440-1448.
- [6] Huang G, Liu Z, Maaten L V D, et al. Densely Connected Convolutional Networks[C]// IEEE Conference on Computer Vision and Pattern Recognition. IEEE Computer Society, 2017:2261-2269.
- [7] Suzuki K, Li F, Sone S, et al. Computer-aided diagnostic scheme for distinction between benign and malignant nodules in thoracic low-dose CT by use of massive training artificial neural network [J]. IEEE Transactions on Medical Imaging, 2005, 24(9):1138-1150.
- [8] Havaei M, Davy A, Warde-Farley D, et al. Brain tumor segmentation with Deep Neural Networks[J]. Medical Image Analysis, 2015, 35:18-31
- [9] Valente I R, Cortez P C, Neto E C, et al. Automatic 3D pulmonary nodule detection in CT images: A survey.[J]. Computer Methods & Programs in Biomedicine, 2016, 124(C):91-107.
- [10] Kumar D, Wong A, Clausi D A. Lung Nodule Classification Using Deep Features in CT Images[C]// Computer and Robot Vision. IEEE, 2015:133-138.
- [11] Shen W, Zhou M, Yang F, et al. Multi-crop Convolutional Neural Networks for lung nodule malignancy suspiciousness classification[J]. Pattern Recognition, 2017, 61(61):663-673.
- [12] Zhu W, Liu C, Fan W, et al. Deeplung: 3d deep convolutional nets for automated pulmonary nodule detection and classification [J]. arXiv:1709.05538, 2017.
- [13] Kang G, Liu K, Hou B, et al. 3D multi-view convolutional neural networks for lung nodule classification[J]. PloS One, 2017, 12(11):12-22.
- [14] Wang C, Elazab A, Wu J, et al. Lung nodule classification using deep feature fusion in chest radiography[J]. Computerized Medical Imaging and Graphics, 2017, 57: 10-18.
- [15] Xie Y, Zhang J, Xia Y, et al. Fusing texture, shape and deep model-learned information at decision level for automated classification of lung nodules on chest CT[J]. Information Fusion, 2018, 42: 102-110.

-
- [16] Armato III S G, McLennan G, Bidaut L, et al. The lung image database consortium (LIDC) and image database resource initiative (IDRI): a completed reference database of lung nodules on CT scans [J]. *Medical physics*, 2011, 38(2): 915-931.
- [17] Glorot X, Bordes A, Bengio Y. Deep Sparse Rectifier Neural Networks[C]// *International Conference on Artificial Intelligence and Statistics*. 2011:315-323.
- [18] Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift [J]. *Computer Science*, 2015:448-456.
- [19] Hinton G E, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. *Computer Science*, 2012, 3(4): 212-223.
- [20] Ingalhalikar M, Parker W A, Bloy L, et al. Using Multiparametric Data with Missing Features for Learning Patterns of Pathology[C]// *International Conference on Medical Image Computing & Computer-assisted Intervention*. *Med Image ComputComput Assist Interv*, 2012:468-75.
- [21] Dhara A K, Mukhopadhyay S, Dutta A, et al. A Combination of Shape and Texture Features for Classification of Pulmonary Nodules in Lung CT Images [J]. *Journal of Digital Imaging*, 2016, 29(4):466-475.